

PIXEL SOFTWARE DESIGN

Département de Recherche & Développement

# Intelligence Artificielle Avancée

## *& Federated Learning*

- Fondations de l'intelligence artificielle
- Algorithmes d'apprentissage fédéré
- Confidentialité, attaques et défenses
- Applications et grands modèles fédérés
- Framework FedX de référence
- Nouveaux fronts de recherche
- Travaux pratiques, projets et évaluation



| | |
|---|---|
| Auteur | **Ghiloufi Jamel** |
| Fonction | **Architecte Logiciel Principal** |
| Direction | **Département de Recherche & Développement** |
| Service | **R&D - Intelligence Artificielle Avancée & Apprentissage Fédéré** |
| Niveau | **Recherche** |
| Édition | **Édition 2026 – 1.0** |
| Copyright | **© Pixel Software Design** |



**Ce document est la propriété exclusive de Pixel Software Design. Toute reproduction, représentation, adaptation ou diffusion, totale ou partielle, par quelque procédé que ce soit et sur quelque support que ce soit, est interdite sans autorisation écrite préalable de l'auteur.**

# Copyright et mentions légales

| | |
|---|---|
| Éditeur | Pixel Software Design |
| Auteur | Ghiloufi Jamel |
| Fonction | Architecte Logiciel Principal |
| Département | Département de Recherche & Développement |
| Intitulé | Intelligence Artificielle Avancée & Federated Learning |
| Sous-titre | Fondations mathématiques de l'apprentissage automatique, algorithmes fédérés, protection de la vie privée, défense contre les attaques, grands modèles de langage fédérés, systèmes embarqués, renforcement appris, applications critiques (santé, V2X), plateforme de référence FedX et feuille de route de recherche. |
| Édition | Édition 2026 (version 1.0) |
| Langue | Français |
| Niveau | Recherche |
| Collection | Supports de formation et de recherche, Pixel Software Design |

## Droits d'auteur

© 2026 Pixel Software Design. Tous droits réservés.

Ce document est la propriété exclusive de Pixel Software Design. Toute reproduction, représentation, adaptation ou diffusion, totale ou partielle, par quelque procédé que ce soit et sur quelque support que ce soit, est interdite sans autorisation écrite préalable de l'auteur.

**Droits de l'auteur.** Ghiloufi Jamel est l'auteur unique de l'ensemble du contenu scientifique, pédagogique et technique de cet ouvrage. Toute adaptation, traduction, reproduction ou exploitation, y compris partielle, requiert une autorisation écrite préalable.

**Droits des tiers.** Les algorithmes, modèles et travaux cités restent la propriété de leurs auteurs respectifs. Les références employées figurent en fin d'ouvrage, ce qui permet de remonter au travail original pour toute affirmation chiffrée.

**Marques et licences externes.** PyTorch, TensorFlow, Flower, Opacus, MONAI, scikit-learn et PySyft sont des logiciels libres sous licences respectives (BSD, Apache 2.0, MIT). Leur usage dans ce document est purement pédagogique et n'emporte aucune prescription commerciale.

## Mentions relatives aux données et aux expérimentations

Document pédagogique à usage de formation interne. Les exemples de code fournis sont livrés à titre pédagogique ; les résultats numériques illustrés sont issus d'expérimentations conduites dans un cadre de recherche et ne constituent pas des performances de production.

Ce support synthétise les travaux de recherche du Département de Recherche & Développement de Pixel Software Design sur l'intelligence artificielle distribuée, l'apprentissage fédéré, la protection de la vie privée et les systèmes embarqués intelligents.

# Sommaire

## Structure détaillée du cours

**Partie 1 — Architectures d'IA : évolution, évaluation et perspectives . . . . . 8**

1.1 La frise des neuf générations . . . . . 9

1.2 Générations 1 à 3 : convolution, récurrence, attention . . . . . 10

1.3 Générations 4 à 6 : état, hybride, mélange d'experts . . . . . 11

1.4 Générations 7 à 9 : agentique, neuromorphique, quantique . . . . . 13

1.5 Évaluer une architecture . . . . . 14

1.6 Acteurs du secteur et travaux fondateurs . . . . . 15

**Annexes . . . . . 18**

A.1 Liste des abréviations . . . . . 19

A.2 Table de notation . . . . . 19

| Partie | Thème | Contenu | Compétence visée | Durée |
|---|---|---|---|---|
| Partie 1 | Fondations | Statistique, optimisation, courbes d'apprentissage | Comprendre et formaliser | 2-3 semaines |
| Partie 2 | Algorithmes FL | FedAvg, convergence, hétérogénéité, système | Implémenter et régler | 3-4 semaines |
| Partie 3 | Confidentialité | DP, attaques, défenses, agrégation sécurisée | Auditer et sécuriser | 2-3 semaines |
| Partie 4 | Applications | FedLLM, santé, V2X, FedRL, TinyML, graphes | Transposer à un domaine | 3-4 semaines |
| Partie 5 | Framework FedX | Architecture, API, benchmarks, exploitation | Industrialiser | 2 semaines |
| Partie 6 | Nouveaux fronts | FedCL, FedCI, SNN, FedGL, feuille de route | Ouvrir la recherche | 2 semaines |
| Partie 7 | TP et projets | 9 labs, 5 projets, corrigés, évaluation | Faire et rendre | 4-6 semaines |

# Préface

### Comment utiliser ce cours

Ce support est conçu pour un parcours de formation et de recherche couvrant l'ensemble de la chaîne de valeur de l'intelligence artificielle distribuée : les fondations mathématiques, les algorithmes d'apprentissage fédéré, les menaces et défenses, les applications de pointe, une plateforme de référence opérationnelle, et enfin les nouveaux fronts ouverts par la recherche du Département.

Ce n'est pas un manuel de référence à lire d'un trait : c'est un **manuel opératoire**. Chaque chapitre alterne exposition, formalisation, mise en œuvre numérique et évaluation. Les listings sont complets et exécutables ; les tableaux comparatifs servent de grille de décision ; les schémas d'architecture servent de support de revue de conception.

## Public et prérequis

Le contenu s'adresse à des étudiants de master et de doctorat, à des ingénieurs IA et à des praticiens de la recherche appliquée. Les prérequis sont la connaissance de l'apprentissage automatique classique, de l'algorithmique numérique et des bases de probabilités. Les parties 1 à 3 sont auto-suffisantes pour un étudiant qui découvre le domaine ; les parties 4 à 7 supposent la mécanique et les outils présentés dans la partie 2.

**Conventions de lecture.** Une expression mathématique est encadrée par deux signes dollars ; un identifiant, un fichier ou une commande est écrit en caractères à chasse fixe ; les encadrés *Définition*, *Théorème*, *Méthode* et *Attention* signalent les points à maîtriser et les pièges fréquents. Les renvois de la forme « voir chapitre 3.2 » désignent le second chapitre de la troisième partie.

## Progression pédagogique

*De la convolution à l'auto-modélisation, et comment on les juge*

**Partie 1**

# Architectures d'IA : évolution, évaluation et perspectives

Les architectures de l'intelligence artificielle se sont remplacées neuf fois en quinze ans, et chaque remplacement a résolu un problème que la génération précédente ne savait pas traiter. Ce cours retracé cette séquence, puis pose la seule question qui compte en production : sur quels critères concrets juge-t-on une architecture, et comment ces critères changent-ils selon la contrainte dominante — la latence, la mémoire, ou le coût.

**Objectifs de la partie**

- Situer les neuf générations et nommer la propriété que chacune ajoute.
- Expliquer pourquoi l'auto-attention a déplacé le coût du calcul vers la mémoire.
- Distinguer une architecture à état d'une architecture récurrente, et dire laquelle convient à quoi.
- Justifier le mélange d'experts par une contrainte de calcul, et non par une mode.
- Évaluer une architecture sur des critères mesurables plutôt que sur des performances annoncées.
- Distinguer ce qui est déployé, ce qui est en recherche, et ce qui relève de la spéculation.

**Plan de la partie**

1. La frise des neuf générations
2. Générations 1 à 3 : convolution, récurrence, attention
3. Générations 4 à 6 : état, hybride, mélange d'experts
4. Générations 7 à 9 : agentique, neuromorphique, quantique
5. Évaluer une architecture
6. Acteurs du secteur et travaux fondateurs

Chapitre 1.1

# La frise des neuf générations

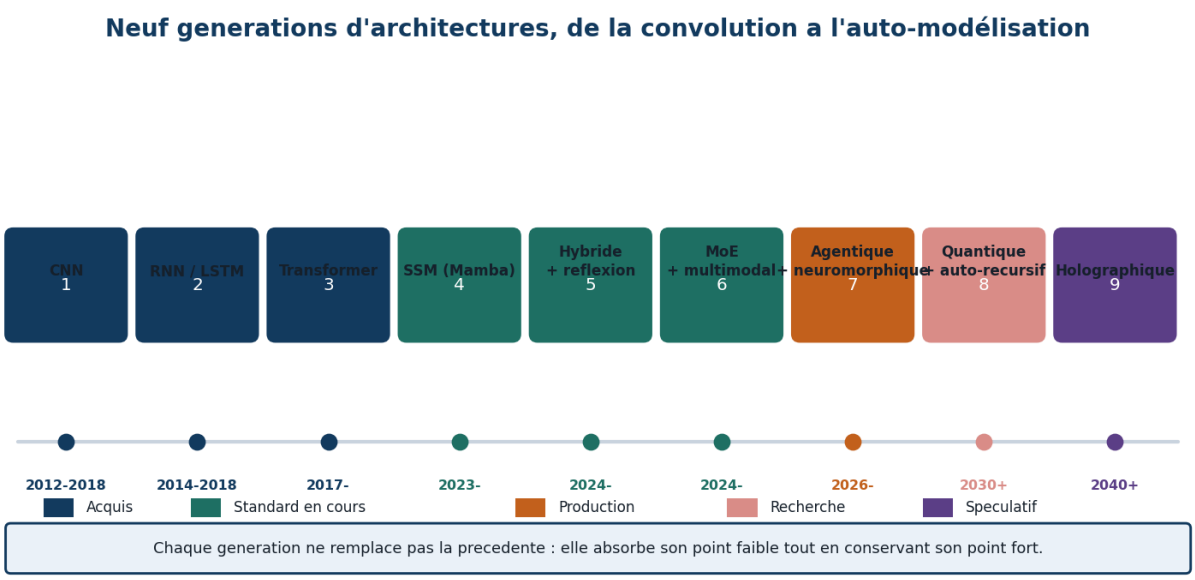



Figure 1 – Les neuf générations et ce que chacune ajoute

| Gén. | Nom | Paradigme | Horizon | Force majeure | Statut |
|---|---|---|---|---|---|
| 1 | CNN | Locale (spatiale) | 2012 – 2018 | Vision par ordinateur | Absorbé par la vision multimodale |
| 2 | RNN / LSTM | Séquentielle O(N) | 2015 – 2019 | Séries temporelles, audio | Obsolète pour le texte |
| 3 | Transformer | Quadratique O($N^2$) | 2017 – présent | Contexte global, génération | Standard de l'industrie |
| 4 | SSM (Mamba) | Linéaire O(N) | 2023 – présent | Vitesse, efficacité mémoire | Croissance forte (Edge) |
| 5 | Hybride et réflexion | Mixte + inférence | 2024 – présent | Raisonnement poussé | Pointe de production |
| 6 | MoE et multimodal | Routage d'experts | 2024 – présent | Efficacité à grande échelle | Standard industriel massif |
| 7 | Agentique et neuromorphique | Distribué, bio-inspiré | 2026 – futur proche | Autonomie, basse consommation | Émergence et recherche |
| 8 | Quantique et auto-récursif | Qubits, auto-modélisation | 2030 et au-delà | Problèmes combinatoires | Recherche fondamentale |
| 9 | Holographique et optique | Photonique, non localisé | 2040 et au-delà (hypothétique) | Résilience, absence de latence | Spéculation théorique |

**Tableau 1 – Les neuf générations d'architectures**

Chaque génération ne remplace pas la précédente : elle ajoute une propriété que la précédente ne pouvait pas exprimer. C'est pourquoi les trois premières restent utilisées en production, chacune pour ce qu'elle fait mieux.

**A retenir**

- Les générations s'ajoutent plus qu'elles ne se remplacent.
- Le coût de l'attention est passé du calcul vers la mémoire.
- L'état, l'hybride et le mélange d'experts répondent à des contraintes de mesure, pas de principe.

- Générations 7 à 9 : ce sont des domaines de recherche, et doivent être lus comme tels.

Chapitre 1.2

# Générations 1 à 3 : convolution, récurrence, attention

Trois hypothèses sur la structure de la dépendance, et trois familles d'architectures qui en découlent.

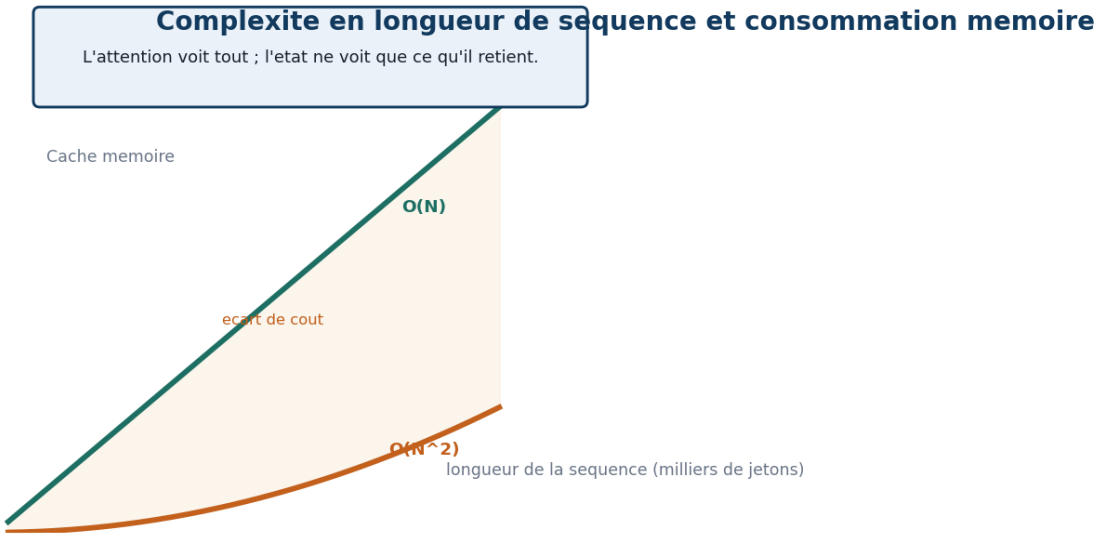



Figure 1 – Le coût comparé des trois hypothèses

| | Convolution | Récurrence | Attention |
|---|---|---|---|
| Hypothèse | la dépendance est locale et stationnaire | la dépendance est strictement ordonnée | la dépendance relie des positions quelconques |
| Portée | limitée par la taille du noyau | limitée par la longueur de la séquence | illimitée, dans la fenêtre du contexte |
| Coût en séquence | O(N) | O(N) | $O(N^2)$ |
| Parallélisme à l'entraînement | par positions | séquentiel | total |
| Point faible | invariance par translation non apprise | oubli sur les longues séquences | coût quadratique en mémoire |
| Terrain naturel | image, signal, audio | série temporelle, texte | texte, code, multimodal |

**Tableau 1 – Convolution, récurrence, attention : la question à laquelle chacune répond**

**Aucune des trois hypothèses n'est fausse : ce sont trois fausses bonnes idées pour trois régimes de données différents. Le transformateur n'a pas rendu la convolution inutile ; il l'a rendue cantonnée à l'image.**

$$\text{Attention}(Q, K, V) = \text{softmax}\leq\text{ft}((Q\,K^{\top})/(\sqrt{(d_k)}) + M)\,V$$
$$\text{Complexité} = O\leq\text{ft}(N^2\,d)\ \text{mémoire},\ O\leq\text{ft}(N^2\,d)\ \text{calcul} \qquad \text{(A.1)}$$

**Le facteur deux n'est pas un défaut d'implémentation mais une conséquence de l'hypothèse : si chaque position peut regarder chaque autre position, il y a N au carré de relations possibles. Réduire ce coût exige de sacrifier l'accès complet : par fenêtre, par échantillonnage, ou par approximation de bas rang.**

**Le déplacement du goulot d'étranglement**

Pendant la transition, le coût dominant de l'attention a changé de nature : le calcul de la matrice de scores est became négligeable devant le stockage des clés et des valeurs. Les architectures materialisées puis fenêtrées ne visent pas à réduire le calcul, mais la mémoire. C'est pourquoi les techniques d'attention efficace sont presque toutes des techniques de gestion de la mémoire, et non du calcul.

**Astuce**

Le choix se fait sur la contrainte, jamais sur l . Un contexte long exige l'attention ; une latence de quelques millisecondes sur un capteur impose l'état ; une séquence très courte et fortement bruitée tolère mieux une règle fixe qu'un modèle appris.

**A retenir**

- Les trois hypothèses de structure donnent trois architectures, et chacune excelle sur son terrain.
- L'attention paie son coût en mémoire avant de le payer en calcul.
- Les architectures matérialisées et fenêtrées visent la mémoire, pas le calcul.
- Le choix se fait sur la contrainte dominante, jamais sur l pertain du procédé.

Chapitre 1.3

# Générations 4 à 6 : état, hybride, mélange d'experts

Trois réponses à la même question : comment tenir la longueur de contexte sans la payer en mémoire ?

- **État d'espace :** un vecteur d'état de taille fixe remplace la séquence. Le coût devient linéaire en longueur, au prix d'un compresseur appris. La perte est réelle : deux contextes distincts peuvent produire le même état.
- **Hybride et réflexion :** on alterne une phase de raisonnement longue et une phase de révision. L'aller-retour coûte deux à trois fois plus qu'un passage direct, et gagne en exactitude sur les tâches où la première réponse était fausse.
- **Mélange d'experts :** plusieurs réseaux specialized, un routeur qui choisit lesquels activer. La qualité s'approche de celle d'un modèle bien plus grand, pour un coût de calcul proche d'un modèle petit. C'est de loin le meilleur rapport gain / coût actuellement disponible.

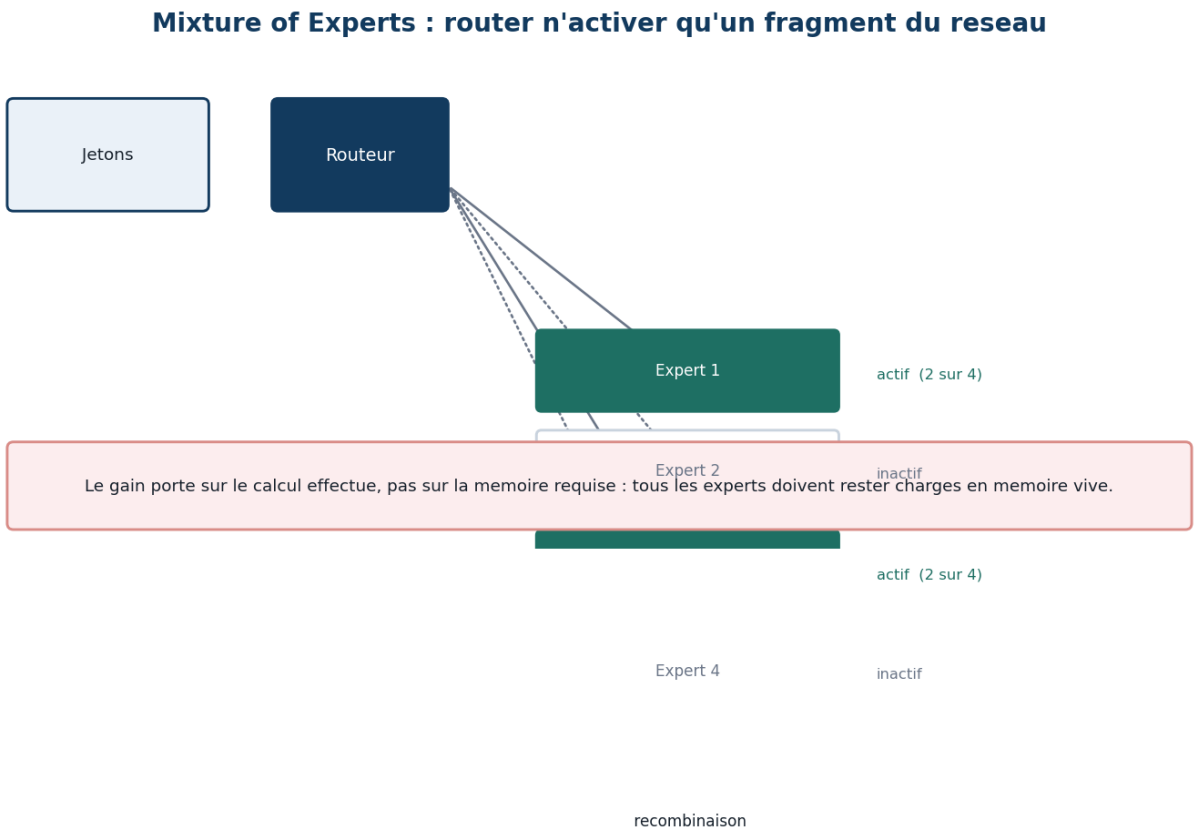



Figure 1 – Le mélange d'experts et la fonction de routage

$$y = \sum_{i=1}^{k} g_i(x)\, E_i(x),\ \sum_i g_i(x) = 1,\ g_i(x) \geq 0$$
$$\text{Coût}(x) = \sum_i g_i(x)\, \text{Coût}(E_i(x)) \qquad \text{(A.2)}$$

**La seconde expression est la raison économique du mélange : le coût est celui des experts activés, non celui de la somme. Le routeur devient donc le point critique – un routeur mal entraîné coûte plus cher que le modèle entier, parce qu'il active trop d'experts et perd les deux avantages à la fois.**

| | État d'espace | Hybride | Mélange d'experts |
|---|---|---|---|
| Gain principal | coût linéaire en longueur | exactitude sur les tâches complexes | qualité / coût |
| Coût caché | compression de l'information | deux à trois passages par question | routeur et déséquilibre d'activation |
| Sensitive à la longueur | très | moyenne | faible |
| Difficulté de mise en œuvre | moyenne | faible | moyenne |
| Maturité industrielle | en croissance | en croissance | déployé à grande échelle |

**Tableau 1 – État, hybride, mélange : comparaison opérationnelle**

**Le mélange d'experts est le plus mûr des trois, et le moins coûteux : son coût de migration est essentiellement nul, puisqu'il s'applique à un modèle existant sans changer son interface.**

### Le routeur qui dégrade le mélange

Un routeur entraîné sur une distribution de requêtes ne fonctionne pas sur une autre, et le symptôme n'est pas une erreur visible : c'est une activation excessive. Le modèle active six experts sur huit, se rapproche de son coût complet, et perd le bénéfice du mélange sans que la qualité chute. Surveiller le nombre d'experts actifs est un indicateur de surveillance, pas un détail d'implémentation.

**A retenir**

- État, hybride et mélange répondent à la même contrainte : tenir la longueur sans payer la mémoire.
- Le mélange d'experts est le meilleur rapport gain / coût disponible, parce que le coût ne suit que les experts activés.
- Le routeur est le point critique : une activation excessive annule les deux avantages.
- Surveiller le nombre d'experts actifs est un indicateur de production.

Chapitre 1.4

# Générations 7 à 9 : agentique, neuromorphique, quantique

Trois domaines de recherche. Les lire comme tels est déjà une compétence professionnelle.

Les trois générations suivantes ne sont pas des improvesments incrémentaux : ce sont des programmes de recherche qui répondent à des limites structurelles de l'architecture actuelle. Les présenter comme des technologies disponibles conduit à des décisions d'investissement erronées.

| Génération | Promesse | Obstacle principal | Statut |
|---|---|---|---|
| Agentique | un système qui planifie et agit | fiabilité sur les actions longues, coût | déploiement encadré, pas autonomie générale |
| Neuromorphique | consommation réduite d'un à trois ordres | entraînement et outillage immature | recherche et quelques pilotes industriels |
| Quantique | accélération de problèmes spécifiques | aucun avantage établi sur une tâche d'IA | recherche fondamentale, sans application |
| Auto-récursif | le modèle améliore son propre code | vérification, coût, boucle de degeneration | recherche, résultats préliminaires |
| Holographique et optique | mémoire et calcul photoniques | intégration, précision, adressage | spéculation théorique |

**Tableau 1 – Générations 7 à 9 : statut réel et ce qu'elles promettent**

**La ligne quantique mérite d'être lue attentivement : l'apprentissage automatique quantique est un domaine de recherche sans application industrielle établie à ce jour. Citer un avantage quantique démontré sur une tâche concrète serait inexact.**

**Un document prospectif sur l'intelligence artificielle se lit en séparant trois registres : ce qui est déployé aujourd'hui, ce qui est en recherche expérimentale, et ce qui relève de la spéculation. Un critère simple : si l'affirmation ne peut pas être testée par une expérience publiée et reproductible, elle relève du troisième registre.**

Précaution de lecture sur les prévisions

**Astuce**

La question utile devant une promesse de génération future n'est jamais « est-ce vrai ? » mais « quelle contrainte actuelle rouvrirait-elle, et qui la finances ? ». Une génération qui ne rouvre aucune contrainte connue n'est pas une génération, c'est un thème.

**A retenir**

- Générations 7 à 9 : programmes de recherche, pas technologies disponibles.
- L'apprentissage automatique quantique n'a aujourd'hui aucune application industrielle établie.
- Lire un document prospectif suppose de séparer trois registres : déployé, recherché, spéculatif.
- La question utile est « quelle contrainte rouvre-t-elle », pas « est-ce vrai ».

Chapitre 1.5

# Évaluer une architecture

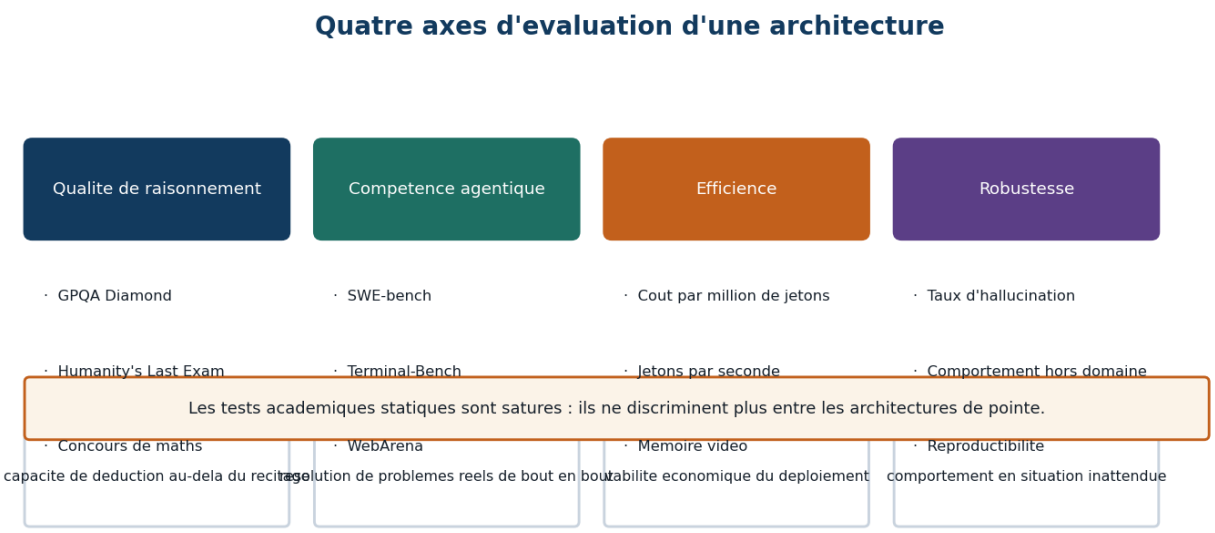



**Figure 1 – Les quatre familles de critères d'évaluation**

Évaluer une architecture revient à choisir un jeu de critères qui correspondent à la contrainte dominante. Comparer deux architectures sans avoir déclaré la contrainte revient à comparer deux réponses à deux questions différentes.

| Famille | Mesures | Ce qu'elle décide | Piège |
|---|---|---|---|
| Qualité | exactitude, robustesse, calibration | le modèle est-il bon en général | mesurée sur une distribution qui ressemble au test |
| Coût | paramètres, mémoire d'inférence, énergie par requête | quelle machine, et quel budget | ignoré au profit du nombre de paramètres seul |
| Latence | temps au premier jeton, débit, variance | l'usage est-il interactif ou différé | mésurée en médiane, jamais au 99e centile |
| Exploitabilité | données requises, domaine de validité, dépendance de version | peut-on l'exploiter à l'échelle | oubliée, et découverte en production |

**Tableau 1 – Quatre familles de critères et ce qu'elles tranchent**

**La famille « exploitabilité » est la plus négligée et la plus coûteuse. Un excellent modèle exigeant une donnée rare est, en pratique, un modèle non déployable.**

$$\text{Coût}_{\text{req}} = c_{\text{mem}} \cdot \text{mémoire} + c_{\text{calc}} \cdot \text{FLOPs} + c_{\text{io}} \cdot \text{octets lus}$$
$$\text{Latence}_{p99} = q_{0,99} \leq \text{ft(durée)} \qquad \text{(A.3)}$$

**La première expression rappelle que le coût d'une requête n'est pas le nombre de multiplications : c'est la somme des accès mémoire et des entrées-sorties, et sur un accélérateur ces deux postes dominent. La seconde rappelle qu'une latence annoncée en médiane ne décrit pas le comportement perçu par un utilisateur.**

### Conduire une comparaison d'architectures en cinq temps

- **Écrire la contrainte dominante en une phrase.** Latence, mémoire, qualité, coût, ou domaine de validité. Pas de réponse valide sans cette phrase.

2. **Fixer le jeu de données d'évaluation avant de voir les résultats.** Un jeu choisi après est un jeu favorable.

3. **Mesurer les quatre familles**, même si la réponse paraît évidente. C'est la mesure qui évite les mauvaises surprises.
4. **Comparer à coût égal, pas à taille égale.** Un modèle deux fois plus grand n'est pas deux fois meilleur ; il faut comparer à paramètres constants.
5. **Tester hors distribution.** Un gain obtenu sur le jeu d'évaluation ne vaut rien s'il s'effondre sur des entrées légitimes mais non couvertes.

**Exercice 1.5.1** (difficulte : Moyen)

Deux modèles obtiennent la même exactitude sur le jeu d'évaluation. Le premier a 7 milliards de paramètres et exige 16 gigaoctets de mémoire d'inférence. Le second en a 3 milliards et en exige 4 gigaoctets. Le service doit répondre en moins de 300 millisecondes sur un matériel disposant de 8 gigaoctets. Quel modèle retenir, et que manque-t-il à la comparaison ?

**Indice :** Deux questions distinctes : la faisabilité matérielle et la mesure de la latence.

**Correction**

- Le second modèle, sans discussion : le premier ne tient pas sur le matériel disponible, et c'est une élimination avant toute autre consideration. La comparaison reste pourtant incomplète : l'égalité des exactitudes ne dit rien de la latence, de la variance, ni de la robustesse hors distribution. Il manque au minimum la latence au 99e centile, le débit soutenu sous charge, et un test de dégradation hors distribution. Une égalité d'exactitude sur un jeu de validation est le point de départ de la comparaison, jamais son conclusion.

**A retenir**

- Évaluer une architecture suppose d'abord d'écrire la contrainte dominante en une phrase.
- Le coût d'une requête est dominé par la mémoire et les entrées-sorties, pas par les multiplications.
- Une latence annoncée en médiane ne décrit pas le comportement perçu : il faut le 99e centile.
- L'exploitabilité — données requises, domaine de validité — est la famille de critères la plus négligée.
- Comparer deux architectures à taille égale n'a pas de sens : il faut comparer à coût égal.

Chapitre 1.6

# Acteurs du secteur et travaux fondateurs

Repérer les travaux qui font référence, et savoir quand ils ont été corrigés ou dépassés.

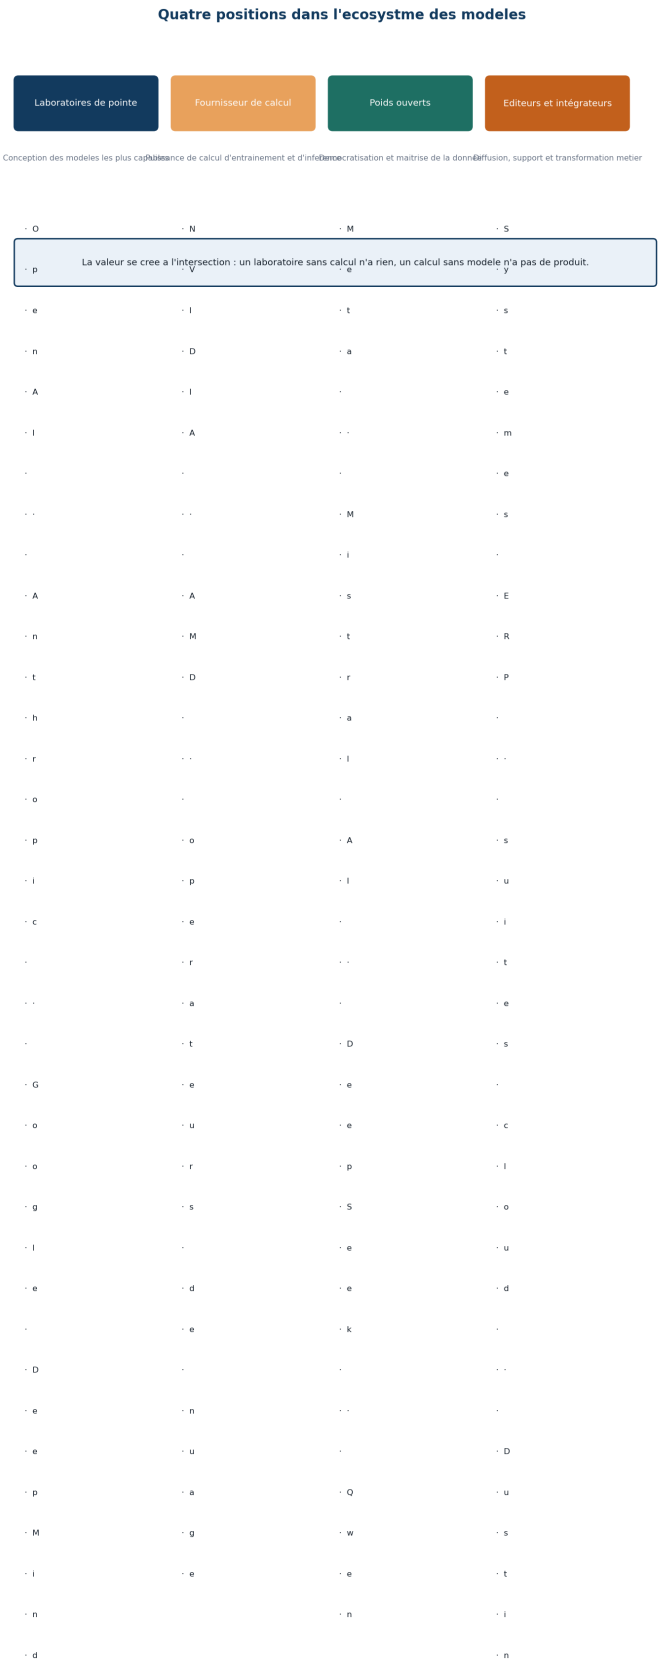



**Figure 1 — Les travaux fondateurs et leur portée réelle**

| Travail | Apport | Statut actuel |
|---|---|---|
| AlexNet, 2012 | profondeur et accélération matérielle sur la vision | travail de référence, dépassé par l'architecture |
| Attention Is All You Need, 2017 | l'attention seule suffit à | le papier le plus cité du domaine, toujours valide |
| LSTM, 1997 | mémoire à porte d'oubli dans la récurrence | utilisé hors texte, remplacé sur le texte |
| Mixture of Experts, 1971 | routage vers des spécialistes | principe ancien, mise en œuvre récente et déployée |
| Scaling Laws, 2020 | lois d'échelle en données et calcul | utilisées pour dimensionner, discutées sur leurs limites |
| Mixture of Depths, 2024 | calcul conditionné à la profondeur | prometteur, déploiement limité |

**Tableau 1 – Travaux fondateurs, ce qu'ils ont établi, et leur statut**

**Le principe du mélange d'experts précède de quarante-six ans son usage industriel. Rappeler cette antériorité est utile : elle montre que l'innovation est souvent dans la mise en œuvre à l'échelle, pas dans l'idée.**

### Ce que la bibliographie ne dit pas

Citer un travail fondateur sans indiquer la version consultée, la configuration expérimentale et les limites déclarées par les auteurs produit une bibliographie trompeuse. Un travail de recherche est un document daté, dans un état daté, et les résultats sont reproductibles ou ne le sont pas. La mention d'une version ou d'un identifiant de dépôt fait partie de la référence.

### Astuce

La question la plus rentable devant une architectureIRC éditée : quels résultats l'article rapporte-t-il, et quels résultats ne rapporte-t-il pas ? Le second point est presque toujours plus informatif que le premier.

### A retenir

- Le mélange d'experts précède de quarante-six ans sa mise en œuvre industrielle : l'innovation est souvent dans l'échelle.
- Un travail de recherche est un document daté, dans un état daté, reproductible ou non.
- Ce qu'un article ne rapporte pas est plus informatif que ce qu'il rapporte.
- La référence complète inclut la version, la configuration et les limites déclarées.

*Abréviations, notation et ressources de consultation*

**Annexes**

# Annexes

Ce cours se termine par deux annexes de référence. La première donne la signification de chaque sigle employé, sous les deux formes — sigle et développé — car la litterature emploie indifféremment l'une ou l'autre. La seconde donne la signification de chaque symbole mathématique : elle permet de relire une démonstration sans revenir au chapitre dont elle est extraite, et de vérifier qu'un même symbole garde le même sens d'un chapitre à l'autre.

Chapitre A.1

# Liste des abréviations

Les sigles ci-dessous sont ceux que le cours emploie. Chacun est donné avec sa forme développée et le sens précis qu'il prend ici, qui n'est pas toujours celui qu'on lui donne ailleurs.

Un sigle employé sans être développé oblige le lecteur à le reconnaître au passage, ou à l'abandonner. Le tableau ci-dessous ferme la liste de ceux que le cours emploie : il est exhaustif pour ce document, et non pour la discipline.

| Sigle | Forme développée | Sens dans ce cours |
|---|---|---|
| CNN | Convolutional Neural Network | Réseau convolutif : première génération, reconnaissance d'images. |
| GNN | Graph Neural Network | Réseau de convolution sur graphe, qui propage l'information selon l'adjacence. |
| LSTM | Long Short-Term Memory | Cellule récurrente à mémoire longue, deuxième génération. |
| MoE | Mixture of Experts | Mélange d'experts : un sous-réseau par jeton, un seul étant activé. |
| MoT | Mixture of Tokens | Mélange opéré au niveau du jeton, et non de l'expert. |
| Mamba | Modèle à convolution sélective | Couche d'espace d'état à balayage sélectif, de coût linéaire en longueur. |
| RNN | Recurrent Neural Network | Réseau récurrent, qui lit une séquence dans l'ordre. |
| SSM | State Space Model | Modèle d'espace d'état, quatrième génération. |
| Transformer | Modèle à mécanisme d'attention | Troisième génération, devenue le standard de l'industrie. |
| ViT | Vision Transformer | Transformer appliqué à l'image, par découpage en jetons. |
| xLSTM | Extended Long Short-Term Memory | Cellule récurrente révisée, dont les opérations sont parallélisables. |

**Tableau 1 – Abréviations employées dans le cours**

Chapitre A.2

# Table de notation

Les symboles ci-dessous gardent le même sens d'un chapitre à l'autre. Lorsqu'un chapitre doit réemployer un symbole pour un autre objet, il le redéclare sur la page même.

La notation est celle du cours : vecteurs en gras, matrices en majuscules grasses, scalaires en italique. Les espérances sont notées $\mathbb{E}$, les lois de données $\mathcal{D}$, les espaces de paramètres $\Theta$.

| Symbole | Signification |
|---|---|
| N | Longueur de la séquence traitée. |
| $d_{model}$ | Dimension du modèle, celle de chaque représentation. |
| $d_k$ | Dimension d'une clé, puis d'une tête d'attention. |
| $d_v$ | Dimension d'une valeur. |
| H | Nombre de têtes d'attention. |
| Q | Matrice des requêtes, pour la i-ième tête d'attention. |
| K | Matrice des clés, dont l'attention pondère les valeurs. |
| V | Matrice des valeurs, que l'attention combine. |
| Attention(Q,K,V) | Sortie d'un bloc d'attention, après masquage causal. |
| O(N) | Complexité linéaire en la longueur de la séquence. |
| $O(N^2)$ | Complexité quadratique, celle de l'attention dense. |
| FLOPs | Nombre d'opérations en virgule flottante, mesure du coût de calcul. |
| MAC | Multiplications-accumulations, unité de mesure matérielle du coût. |
| α | Efficience, rapport du travail utile au travail total. |
| K | Nombre d'experts actifs dans un mélange d'experts. |
| g(x) | Fonction de routage, qui désigne l'expert d'un jeton. |
| h | Nombre de tours de récurrence, ou hauteur d'un réseau. |

**Tableau 1 – Symboles mathématiques et leur signification**

> **Convention**
> Toute divergence constatée entre cette table et un chapitre signale une erreur de transcription, non une définition nouvelle : la table fait foi.

> **A retenir**
> - Un sigle employé sans être listé ici est un oubli de l'auteur, non une définition nouvelle.
> - Un symbole qui change de sens d'un chapitre à l'autre rend toute démonstration ininterprétable : c'est la principale cause des contresens que nous avons relevés.
> - Ces deux tables sont les seules parties du cours à maintenir à la main : le reste se relit tout seul.

# Index des figures et des tableaux

### Référence rapide du matériel visuel

## Figures

1. Les neuf générations et ce que chacune ajoute
1. Le coût comparé des trois hypothèses
1. Le mélange d'experts et la fonction de routage
1. Les quatre familles de critères d'évaluation
1. Les travaux fondateurs et leur portée réelle

# Tableaux

1. Les neuf générations d'architectures
1. Convolution, récurrence, attention : la question à laquelle chacune répond
1. État, hybride, mélange : comparaison opérationnelle
1. Générations 7 à 9 : statut réel et ce qu'elles promettent
1. Quatre familles de critères et ce qu'elles tranchent
1. Travaux fondateurs, ce qu'ils ont établi, et leur statut
1. Abréviations employées dans le cours
1. Symboles mathématiques et leur signification

# Fin du document

**Intelligence Artificielle Avancée & Federated Learning** — Fondations mathématiques de l'apprentissage automatique, algorithmes fédérés, protection de la vie privée, défense contre les attaques, grands modèles de langage fédérés, systèmes embarqués, renforcement appris, applications critiques (santé, V2X), plateforme de référence FedX et feuille de route de recherche.<br/>Ghiloufi Jamel, Architecte Logiciel Principal — Pixel Software Design<br/>Département de Recherche & Développement — Recherche<br/>Pixel Software Design — Édition 2026

© 2026 Pixel Software Design. Tous droits réservés.

Ce document est la propriété exclusive de Pixel Software Design. Toute reproduction, représentation, adaptation ou diffusion, totale ou partielle, par quelque procédé que ce soit et sur quelque support que ce soit, est interdite sans autorisation écrite préalable de l'auteur.

Document généré automatiquement le 29/09/2026 – mise en page Pixel Software Design.