

PIXEL SOFTWARE DESIGN

Département de Recherche & Développement

Intelligence Artificielle Avancée

& Federated Learning

- Fondations de l'intelligence artificielle
- Algorithmes d'apprentissage fédéré
- Confidentialité, attaques et défenses
- Applications et grands modèles fédérés
- Framework FedX de référence
- Nouveaux fronts de recherche
- Travaux pratiques, projets et évaluation

Auteur	**Ghiloufi Jamel**
Fonction	**Architecte Logiciel Principal**
Direction	**Département de Recherche & Développement**
Service	**R&D - Intelligence Artificielle Avancée & Apprentissage Fédéré**
Niveau	**Recherche**
Édition	**Édition 2026 – 1.0**
Copyright	**© Pixel Software Design**

Ce document est la propriété exclusive de Pixel Software Design. Toute reproduction, représentation, adaptation ou diffusion, totale ou partielle, par quelque procédé que ce soit et sur quelque support que ce soit, est interdite sans autorisation écrite préalable de l'auteur.

Copyright et mentions légales

Éditeur	Pixel Software Design
Auteur	Ghiloufi Jamel
Fonction	Architecte Logiciel Principal
Département	Département de Recherche & Développement
Intitulé	Intelligence Artificielle Avancée & Federated Learning
Sous-titre	Fondations mathématiques de l'apprentissage automatique, algorithmes fédérés, protection de la vie privée, défense contre les attaques, grands modèles de langage fédérés, systèmes embarqués, renforcement appris, applications critiques (santé, V2X), plateforme de référence FedX et feuille de route de recherche.
Édition	Édition 2026 (version 1.0)
Langue	Français
Niveau	Recherche
Collection	Supports de formation et de recherche, Pixel Software Design

Droits d'auteur

© 2026 Pixel Software Design. Tous droits réservés.

Ce document est la propriété exclusive de Pixel Software Design. Toute reproduction, représentation, adaptation ou diffusion, totale ou partielle, par quelque procédé que ce soit et sur quelque support que ce soit, est interdite sans autorisation écrite préalable de l'auteur.

Droits de l'auteur. Ghiloufi Jamel est l'auteur unique de l'ensemble du contenu scientifique, pédagogique et technique de cet ouvrage. Toute adaptation, traduction, reproduction ou exploitation, y compris partielle, requiert une autorisation écrite préalable.

Droits des tiers. Les algorithmes, modèles et travaux cités restent la propriété de leurs auteurs respectifs. Les références employées figurent en fin d'ouvrage, ce qui permet de remonter au travail original pour toute affirmation chiffrée.

Marques et licences externes. PyTorch, TensorFlow, Flower, Opacus, MONAI, scikit-learn et PySyft sont des logiciels libres sous licences respectives (BSD, Apache 2.0, MIT). Leur usage dans ce document est purement pédagogique et n'emporte aucune prescription commerciale.

Mentions relatives aux données et aux expérimentations

Document pédagogique à usage de formation interne. Les exemples de code fournis sont livrés à titre pédagogique ; les résultats numériques illustrés sont issus d'expérimentations conduites dans un cadre de recherche et ne constituent pas des performances de production.

Ce support synthétise les travaux de recherche du Département de Recherche & Développement de Pixel Software Design sur l'intelligence artificielle distribuée, l'apprentissage fédéré, la protection de la vie privée et les systèmes embarqués intelligents.

Sommaire

Structure détaillée du cours

Partie 1 — IA et Audio Génératif 8

1.1 La chaîne de génération audio 9

1.2 Génération musicale et cohérence de longue durée 10

1.3 Filigrane sonore et traçabilité 11

1.4 Codecs neuronaux et qualité de reconstruction 13

1.5 Audio spatial et rendu temps réel 14

Annexes 18

A.1 Liste des abréviations 19

A.2 Table de notation 19

Partie	Thème	Contenu	Compétence visée	Durée
Partie 1	Fondations	Statistique, optimisation, courbes d'apprentissage	Comprendre et formaliser	2-3 semaines
Partie 2	Algorithmes FL	FedAvg, convergence, hétérogénéité, système	Implémenter et régler	3-4 semaines
Partie 3	Confidentialité	DP, attaques, défenses, agrégation sécurisée	Auditer et sécuriser	2-3 semaines
Partie 4	Applications	FedLLM, santé, V2X, FedRL, TinyML, graphes	Transposer à un domaine	3-4 semaines
Partie 5	Framework FedX	Architecture, API, benchmarks, exploitation	Industrialiser	2 semaines
Partie 6	Nouveaux fronts	FedCL, FedCI, SNN, FedGL, feuille de route	Ouvrir la recherche	2 semaines
Partie 7	TP et projets	9 labs, 5 projets, corrigés, évaluation	Faire et rendre	4-6 semaines

Préface

Comment utiliser ce cours

Ce support est conçu pour un parcours de formation et de recherche couvrant l'ensemble de la chaîne de valeur de l'intelligence artificielle distribuée : les fondations mathématiques, les algorithmes d'apprentissage fédéré, les menaces et défenses, les applications de pointe, une plateforme de référence opérationnelle, et enfin les nouveaux fronts ouverts par la recherche du Département.

Ce n'est pas un manuel de référence à lire d'un trait : c'est un **manuel opératoire**. Chaque chapitre alterne exposition, formalisation, mise en œuvre numérique et évaluation. Les listings sont complets et exécutables ; les tableaux comparatifs servent de grille de décision ; les schémas d'architecture servent de support de revue de conception.

Public et prérequis

Le contenu s'adresse à des étudiants de master et de doctorat, à des ingénieurs IA et à des praticiens de la recherche appliquée. Les prérequis sont la connaissance de l'apprentissage automatique classique, de l'algorithmique numérique et des bases de probabilités. Les parties 1 à 3 sont auto-suffisantes pour un étudiant qui découvre le domaine ; les parties 4 à 7 supposent la mécanique et les outils présentés dans la partie 2.

Conventions de lecture. Une expression mathématique est encadrée par deux signes dollars ; un identifiant, un fichier ou une commande est écrit en caractères à chasse fixe ; les encadrés *Définition*, *Théorème*, *Méthode* et *Attention* signalent les points à maîtriser et les pièges fréquents. Les renvois de la forme « voir chapitre 3.2 » désignent le second chapitre de la troisième partie.

Progression pédagogique

De la description textuelle à la scène sonore

Partie 1

IA et Audio Génératif

L'audio est le dernier grand médium à avoir été transformé par l'apprentissage automatique, et il s'oppose aux autres sur un point : l'encre est irréversible. Une image générée peut être corrigée par une retouche ; une milliseconds de son fausse ne peut pas être rattrapée. Ce cours décrit la chaîne technique de la génération sonore, et insiste sur ce qui la rend sensiblement différente de tout le reste : la continuité temporelle, la restauration après transformation, et l'exigence de traçabilité de l'origine.

Objectifs de la partie

- Décrire la chaîne complète, de la description textuelle au flux audio, et situer le rôle du codec.
- Expliquer pourquoi la cohérence d'une composition longue est un problème distinct de la qualité locale.
- Comprendre ce qu'un filigrane sonore garantit, ce qu'il ne garantit pas, et pourquoi ce n'est pas une preuve.
- Distinguer un codec appris d'un codec à formule, et expliquer pourquoi les deux qualités se mesurent séparément.
- Dimensionner un budget temps réel et justifier le partage entre acquisition, traitement et restitution.
- Expliquer comment une source sonore générée devient mobile sans recalcul géométrique.

Plan de la partie

1. La chaîne de génération audio
2. Génération musicale et cohérence de longue durée
3. Filigrane sonore et traçabilité
4. Codecs neuronaux et qualité de reconstruction
5. Audio spatial et rendu temps réel

Chapitre 1.1

La chaîne de génération audio

L'audio de qualité n'est pas un fichier : c'est une reconstruction, et la reconstruction a un coût.

La génération audio repose sur une idée simple et une idée difficile. L'idée simple : comme le texte, le son peut être découpé en unités discrètes et traité par un modèle de séquence. L'idée difficile : ces unités doivent être apprises, pas fixées, et la qualité dépend autant du codec qui transporte le son que du modèle qui le compose.

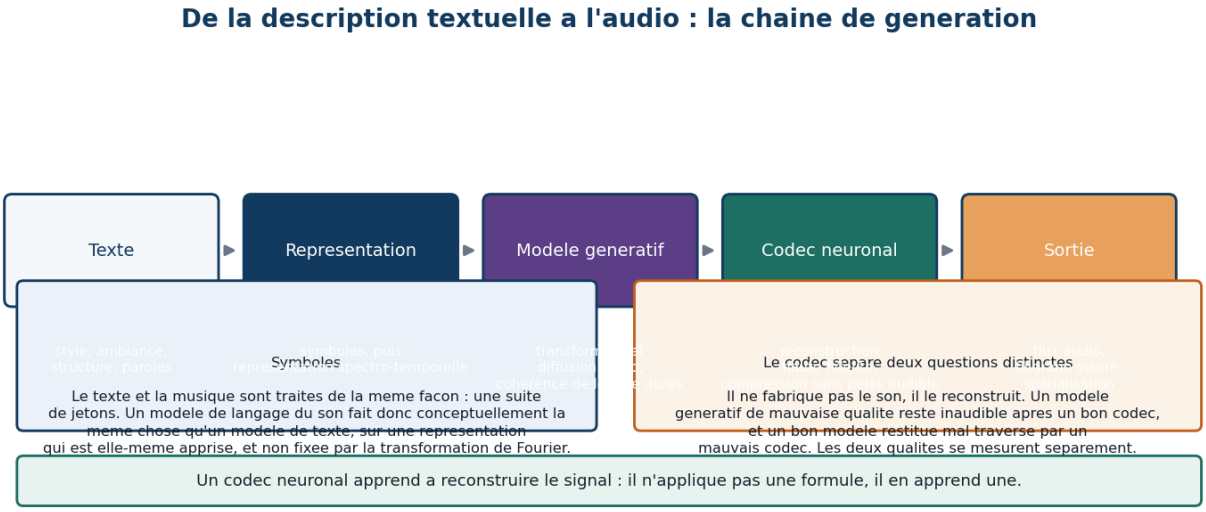


Figure 1 – De la description textuelle à l'audio : la chaîne de génération

$$\text{hatmathbfa} = D\leq ft(E\leq ft(\text{mathbfa})), \quad L = \leq ft| \text{mathbfa} - D(E(\text{mathbfa})) |^2 + \lambda \leq ft| z_{enc}(\text{mathbfa}) - z_{tgt} |^2 \tag{A.1}$$

L'encodeur E transforme le signal en une représentation discrète, le décodeur D la reconstruit. La seconde partie de la perte contraint l'espace de représentation à ressembler à un espace de texte, ce qui permet au même mécanisme d'autorégression de servir aux deux. Le son est donc traité comme une langue dont l'alphabet est appris.

Étape	Fonction	Échec typique	Détection
Description	exprimer l'intentiondescription trop pauvre, résultat générique	impossible à détecter sans écoute comparative	
Représentation	projeter le son en jetons	perte d'information dans les transitoires	audible sur les percussions
Génération	produire la séquence	cohérence qui se dégrade sur la durée	audible à l'écoute attentive, en fin de morceau
Décodage	reconstruire le signal	distorsion de la reconstruction	mesurable, par comparaison
Spatialisation	placer les sources	image auditive incohérente	mesurable, par comparaison

Tableau 1 – Les cinq étapes et ce qui peut y échouer

La colonne de droite est la plus utile en pratique : les deux dernières étapes sont mesurables, donc automatisables en recette, et c'est là que la qualité se gagne sans aucun travail d'écoute.

Évaluer une chaîne de génération audio, en cinq mesures

- **Taux d'artefacts transitoires** : proportion d'événements percussifs dont la reconstruction présente un pré-éclairement. C'est le défaut le plus caractéristique d'un codec appris sous-entraîné, et il est mesurable automatiquement.

2. **Ratio de compression perçu** : à qualité égale, combien de bits par seconde. Cette mesure doit être faite sur une écoute aveugle, jamais sur une comparaison visuelle des spectrogrammes.
3. **Dérive de cohérence** : écart entre les métriques calculées sur le premier quart et sur le dernier quart du morceau. Une dégradation régulière est le signé le plus fiable d'une perte de cohérence en fin de composition.
4. **Loyauté à la description** : distance entre les attributs musicaux extraits du signal et ceux demandés. Mesure dificilement automatisable, mais qui doit être effectuée par un panel.
5. **Taux de détection du filigrane** : proportion de sorties où le filigrane est retrouvé après compression et après reconversion. C'est la seule mesure qui rende la traçabilité opérationnelle.

Le codec sépare deux qualités distinctes

Un modèle génératif médiocre reste inaudible après un bon codec : la reconstruction est fidèle à ce que le modèle a produit. Réciproquement, un bon modèle dont la sortie traverse un mauvais codec perd précisément les transitoires qui portent l'information rythmique. Les deux qualités se mesurent séparément, s'optimisent séparément, et un test qui les confond ne peut conclure sur aucune des deux.

A retenir

- L'audio est traité comme une langue dont l'alphabet est appris, non comme un signal à compresser.
- La représentation apprise perd d'abord les transitoires, qui portent l'information rythmique.
- La qualité du modèle et celle du codec se mesurent et s'optimisent séparément.
- Les deux dernières étapes de la chaîne sont automatisables, et c'est là que la qualité se gagne sans travail d'écoute.

Chapitre 1.2

Génération musicale et cohérence de longue durée

Une suite de notes justes n'est pas une composition. La cohérence est un problème de structure, pas de sonorité.

La génération musicale a une difficulté propre, absente de la génération d'images : le temps. Une image est jugée dans son ensemble, ce qui permet au modèle d'optimiser globalement. Un morceau de trois minutes est jugé par son intérieur, et un modèle qui optimisé note par note produit une suite localement correcte et globalement incohérente.

$$p(x_{1:T}) = \prod_{t=1}^{T} p(x_t \mid x_{1:t-1}, c), \text{ dégradation : } M(x_{1:q}) \neq M(x_{T-q:T}) \quad \text{(A.2)}$$

Le produit montre que la vraisemblance d'un morceau multiplie les probabilités élémentaires : un décalage de routine de quelques centièmes suffit à rendre un morceau de plusieurs minutes improbable. La seconde expression est la mesure opérationnelle du problème : on compare les métriques structurelles du début et de la fin.

Mécanisme	Ce qu'il maintient	Limite
Contexte étendu	la tonalité et l'harmonie sur la duréecoût croissant avec la longueur du contexte	
Reprise de motifs	l'identité thématique	produit de la répétition si mal maîtrisé
Conditionnement global	le style, le genre, l'instrumentation	ne garantit pas la structure interne
Planification explicite	la forme : introduction, couplet, refrain, transition	impose une structure au texte musical

Tableau 1 – Les quatre mécanismes qui maintiennent la cohérence

Le quatrième mécanisme est le plus efficace et le moins utilisé spontanément. On ne demande pas à un modèle de produire une chanson, on lui demande de produire une section, avec des consignes distinctes pour chacune.

Contrôler la forme plutôt que la substance

- **Découper en sections** de vingt à quarante secondes : introduction, couplet, refrain, pont, conclusion.

2. **Rédiger les paroles section par section**, en indiquant ce que la section doit faire et non seulement ce qu'elle doit contenir.
3. **Fixer les paramètres de style par section**, et les faire varier de façon contrôlée : le refrain revient avec la même signature, le pont la modifie.
4. **Générer chaque section indépendamment**, puis les assembler.
5. **Vérifier la continuité tonale à l'assemblage**, et refaire la section en cas de rupture.

L'étape 5 est celle qui produit la plus grande amélioration immédiate, et celle que l'on ne fait pas parce que l'assemblage semble évident.

Un système qui respecté parfaitement la description produit une musique inaudible, parce que l'absence de contraste est elle-même une audibilité nulle. Les termes « faible variation » et « aléatoire » sont tous deux des défauts, et le style est précisément ce qui se tient entre les deux. Les métriques de fidélité au style ne détectent aucun des deux défauts : elles mesurent la conformité, pas l'effet.

Confondre fidélité au style et absence d'effet

Astuce

Écoutez toujours la jonction, pas seulement les sections. L'essentiel de l'impression de qualité se joue sur les deux secondes qui entourent chaque couture, et c'est exactement là que l'name d'assemblage ne regarde jamais.

A retenir

- Le temps est la difficulté propre de la génération musicale, absente de la génération d'images.
- Quatre mécanismes maintiennent la cohérence, dont la planification explicite de la forme est la plus efficace.
- Contrôler la forme section par section est plus fiable que de demander un morceau entier.
- Les métriques de fidélité au style mesurent la conformité, et ne détectent ni l'absence de contraste ni le désordre.

Chapitre 1.3

Filigrane sonore et traçabilité

Un filigrane n'est pas une preuve : c'est un signal dont la détection est une hypothèse statistique.

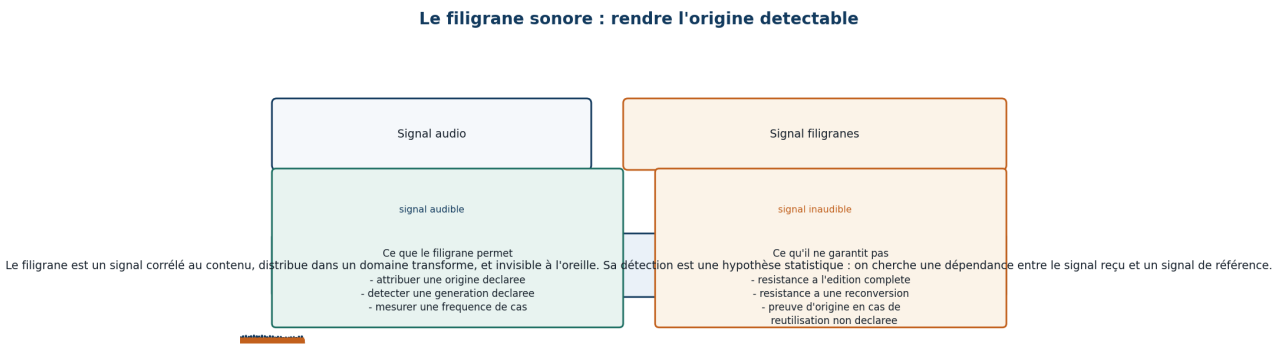


Figure 1 – Le filigrane sonore : rendre l'origine détectable

Rendre l'origine d'un contenu généré détectable est un problème de difficulté réelle, et non une formalité. Le signal est bruité, compressé, ré-échantillonné, parfois ressorti d'une vidéo. Le filigrane doit survivre à tout cela tout en restant inaudible. Ces deux exigences sont en tension : ce qui résiste à la compression introduit des artefacts audibles.

$$s' = s + \alpha\, w,\ w \perp\!\!\!\perp s,\ E\leq ft[\ \leq ft|\ D(s') - D(s)\ |\ ]\ \leq \varepsilon \qquad \text{(A.3)}$$

La première relation définit l'injection : un signal indépendant du contenu, ajouté à faible amplitude. La seconde contrainte est celle de l'imperceptibilité, et c'est elle qui plafonne la robustesse. Un filigrane plus robuste coûte de l'audibilité, jamais l'inverse.

Propriété	Vrai ?	Ce qu'il faut écrire à la place
Le contenu est d'origine humaine	fauxaucun filigrane ne prouve une origine humaine	
Le contenu a été généré par un modèle déclaré	impossible	on peut seulement établir une probabilité de détection
Le filigrane résiste à la compression	partiellement	le taux de survie doit être mesuré et publié
Le filigrane résiste à l'édition	faiblement	l'édition est le point faible principal
Le contenu est conforme à une licence	faux	la licence est une question de droit, pas de signal
Le contenu porte une attribution	vrai, si le signal est	l'attribution porte sur l'origine déclarée, rien de plus

Tableau 1 – Ce que le filigrane garantit et ce qu'il ne garantit pas

La troisième colonne est la seule formulation acceptable dans une politique d'usage. La première colonne pose la question, la deuxième montre ce qu'on ne peut pas affirmer, et la troisième indique ce qu'on peut dire.

Un test de filigrane n'est pas un test de vérité

Un test qui répond « présent » prouve qu'un signal statistique détecté est cohérent avec le filigrane attendu. Un test qui répond « absent » ne prouve pas l'absence de génération : le signal a été effacé, l'audio a été retraité, ou le test est faux positif dans l'autre sens. Traiter une absence de détection comme une preuve d'innocence, ou une détection comme une preuve de culpabilité, sont deux erreurs symétriques et toutes deux fréquentes. Le seul usage défendable est statistique et agrégé : estimer une fréquence sur un corpus, jamais conclure sur un cas unique.

Cadre juridique de l'audio généré

Trois régimes doivent être distingués selon les juridictions, et les confondre est la principale source d'erreur juridique. **Droit d'auteur :** une œuvre créée par une personne est protégée ; une œuvre purement générée par une machine est, dans la plupart des systèmes juridiques, dépourvue d'auteur, donc tombant dans le domaine public — sauf si l'humain peut être identifié comme auteur de la conception, ce qui est discuté. **Droit des interprètes :** la voix d'un interprète reste protégée, et sa synthèse sans consentement relève de protections spécifiques, indépendantes du droit d'auteur. **Droit de la publicité et de l'information :** la prospective juridique de certains juridictions va jusqu'à interdire la synthèse vocale non déclarée, ce qui déplace le problème de l'auteur vers l'information de l'auditeur. Un dispositif de filigrane sert ici moins à prouver qu'à informer, et c'est souvent là qu'il trouve sa justification la plus solide.

Astuce

Le bon usage d'un filigrane n'est pas la Enforcement, c'est l'information. Afficher une mention, publier un taux de survie mesuré, et documenter les limites : cela protège l'émetteur et l'auditeur bien mieux qu'une détection binaire présenté comme une preuve.

A retenir

- L'injection d'un filigrane et l'imperceptibilité sont en tension : la robustesse se paie en audibilité.
- Un test de filigrane est une estimation statistique, jamais une preuve sur un cas unique.
- L'absence de détection ne prouve pas l'absence de génération, pas plus que la détection ne prouve la culpabilité.
- L'usage le plus solide du filigrane est l'information de l'auditeur, avec des limites publiées.

Chapitre 1.4

Codecs neuronaux et qualité de reconstruction

Un codec appris n'applique pas une formule : il en apprend une. Toute la difficulté est là.

La compression audio classique repose sur une décomposition en fréquences, un classement par importance, et un codage arithmétique. L'opération décisive — deciding ce qui compte et ce qui peut être détruit — y est fixée à l'avance par le concepteur. Un codec neuronal apprend cette opération à partir d'exemples, ce qui lui permet d'atteindre des débits bien inférieurs à qualité égale.

$$\text{hatmathbfa} = D_\theta(E_\phi(\text{mathbfa})),\ r(b) = (-\log_2 P(\text{hatmathbfa}))/(b),\ \text{MMSE}(r, s) = \operatorname{argmin}_r \leq\text{ft}[\ r + \lambda\ D(E_r(\text{mathbfa}), \text{mathbfa})\ ] \tag{A.4}$$

Le débit se lit directement dans le nombre de bits par échantillon : moins le modèle est contraint, moins il produit de bits. Le terme final est la forme générale du compromis débit-distorsion, et c'est le paramètre de conception central d'un codec neuronal.

Critère	Codec à formule	Codec appris	Qui gagne
Débit à qualité égale	élevé	très faible	appris
Comportement sur contenu inconnu	prédit par la formule	imprédit, mesuré seulement par essai	formule
Fidélité de la phase	excellente	parfois dégradée	formule, pour la voix
Coût de calcul	faible	élevé	formule
Adaptation à un usage	impossible sans réécrire	réentraînement ciblé	appris
Explicabilité de la perte	totale	faible	formule
Robustesse de la recette	un test suffit	il faut un corpus de référence	formule

Tableau 1 – Codec à formule et codec appris : la comparaison honnête

Un codec appris est meilleur en débit et pire en explicabilité, ce qui a une conséquence directe : il faut construire une recette de référence, et cette recette coûte plus cher que le codec lui-même.

Construire une recette de référence pour un codec

- **Constituer un corpus représentatif** de ce que l'usage réel transporte : voix, musique, sons de ville, silence. Un corpus homogène produit un codec excellent sur un contenu et inutilisable sur les autres.

2. **Définir la métrique de référence**, et une seule. Un test multi-métriques finit toujours par être ajusté sur la métrique la plus commode, pas la plus pertinente.
3. **Fixer le débit et le délai de reconstruction** comme paramètres de recette, et non comme paramètres d'évaluation.
4. **Ajouter le test de régression le plus dur** : un début et une fin silencieux, parce que c'est là que les artefacts d'encodage se font entendre.
5. **Décider de la conduite en cas d'échec** : dégrader le débit, ou refuser la transmission. Cette décision doit être automatisée, car elle sera prise en charge, à trois heures du matin, par un composant.

Astuce

Le test de régression le plus rentable pour un codec audio est l'écoute d'un silence suivi d'un début. Presque tous les défauts d'encodage s'y manifestent, et ce test prend deux minutes.

A retenir

- L'opération décisive d'un codec — ce qui peut être détruit — est fixé dans un codec à formule et apprise dans un codec neuronal.
- Le débit se lit dans le nombre de bits par échantillon ; la contrainte de qualité le détermine.
- Un codec appris exige une recette de référence, et cette recette coûte plus cher que le codec.
- Le test de régression le plus rentable est un silence suivi d'un début.

Chapitre 1.5

Audio spatial et rendu temps réel

Un son généré est mobile par construction : la position suffit, aucun recalcul géométrique n'est nécessaire.

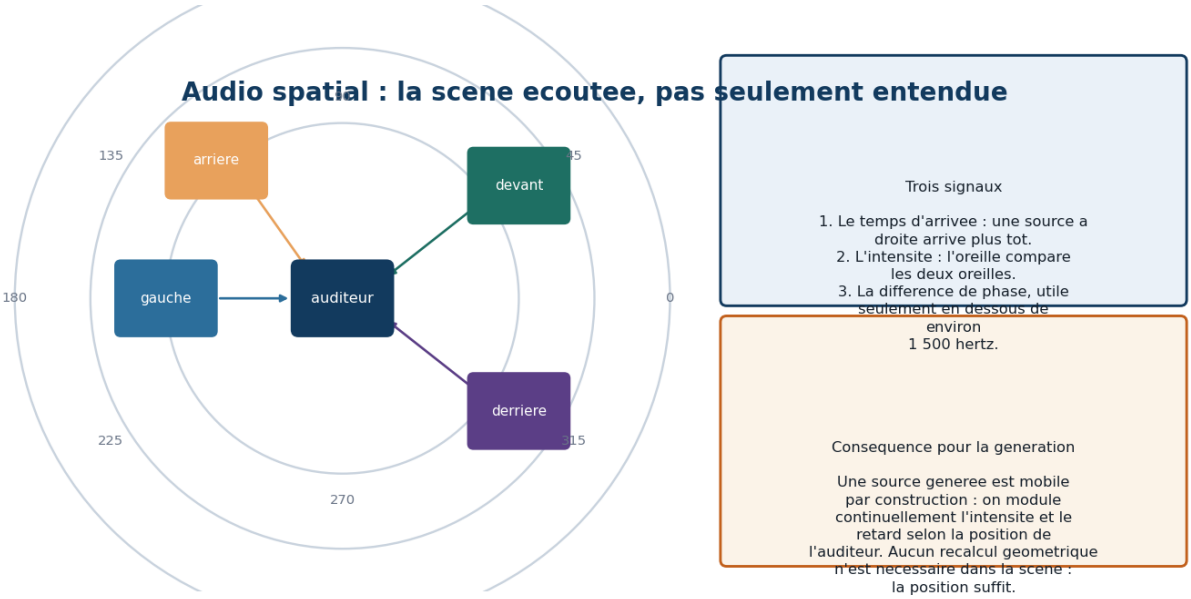


Figure 1 — Audio spatial : la scène écoutée, pas seulement entendue

L'audio spatial se repose sur trois signaux physiques, tous mesurables et tous calculables à partir d'une position : le temps d'arrivée relatif, la différence d'intensité, et la différence de phase. Ils suffisent à localiser une source. La conséquence pratique est considérable pour la génération : une source synthétisée est mobile sans coût, puisque la position de l'auditeur suffit à recalculer les trois signaux en continu.

$$\Delta t \approx (d_g - d_d)/(c),\ I_g \propto (1)/((d_g + h)^2),\ \Delta \varphi = (2\pi f \leq ft(\ d_d - d_g\ ))/(c) \qquad \text{(A.5)}$$

La différence de phase n'est exploitable que lorsque le décalage de chemin reste inférieur à une demi-longueur d'onde, soit environ 1 500 hertz pour une vitesse de son de 340 mètres par seconde. Au-delà, l'oreille perd complètement l'information de phase, et la localisation se fait sur les deux autres signaux — ce qui explique que la précision perçue chute brutalement avec la distance sur les sources aiguës.

Moduler une source générée selon la position d'écoute

- **Partir d'une source monaurale** de bonne qualité, et ne pas générer directement une source stéréo : la correction de position s'applique mieux à un signal de référence.

2. **Calculer les deux distances** de la source à chaque oreille, à chaque instant : c'est une opération de trois multiplications, négligeable devant le rendu.
3. **Appliquer le retard et l'atténuation**, et non un simple panoramique. Un panoramique ne modélise ni la distance, ni l'occlusion, ni la propagation dans un espace fermé.
4. **Modéliser l'occlusion** par filtrage passe-bas variable, puis par atténuation, dans cet ordre : un obstacle de petite dimensionné absorbe surtout les hautes fréquences.
5. **Ajouter la réverbération** de l'espace, avec une durée de réverbération et un temps de pré-délai qui varient avec la distance et la taille de la pièce.
6. **Vérifier l'audition** au point de l'auditeur, et non au point d'émission : c'est là que la scène est perçue.

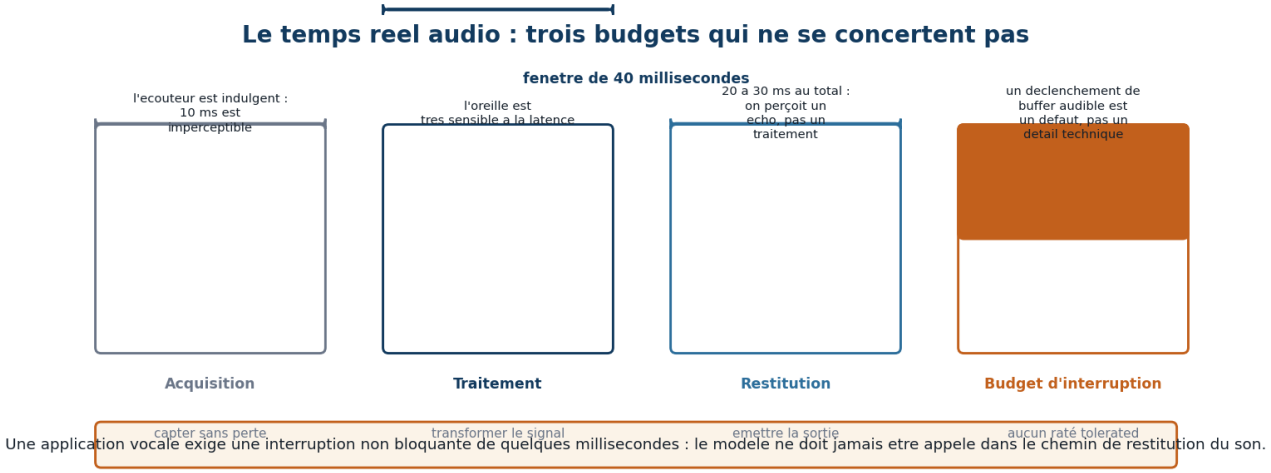


Figure 2 – Le temps réel audio : trois budgets qui ne se concertent pas

Phase	Budget	Ce qui peut s'y passer	Ce qui ne peut pas s'y passer
Acquisition	10 ms	captation, conversion, tampon	aucun appel à un service distant
Traitement	20 ms	filtrage, mélange, synthèse courte	un appel à un modèle de génération de plusieurs secondes
Restitution	10 ms	lecture, mélange final	aucune attente de quelqueque nature

Tableau 1 – Le partitionnement du budget de 40 millisecondes

Un appel à un modèle de génération de plusieurs secondes ne peut pas se trouver dans le chemin de restitution. La solution est toujours la même : produire à l'avance, mettre en tampon, et laisser le tampon amortir l'attente en acceptant un retard de quelques dizaines de millisecondes.

L'erreur est intuitive et apparaît régulièrement : dès que la latence de l'appel dépasse le budget de la fenêtre audio, on entend un décrochage. Ce n'est pas un défaut de qualité sonore, c'est un défaut de conception. La parade comporte deux volets : un tampon dimensionné pour la pire latence observée, avec une politique explicite en cas de dépassement – silence, son de repli, ou message – et une surveillance du taux de dépassement, qui est un indicateur de service à part entière.

Appeler un modèle distant depuis le chemin de restitution

Travaux pratiques 1.1 – Budget temps réel et politique de repli

Duree : 3 h | Niveau : Avance | Outils : Un banc de mesure de latence, une fenêtre de 40 millisecondes, et deux appels de service de durées contrôlées

Construire une chaîne audio à budget contraint et définir la conduite à tenir quand le budget est dépassé.

Deroulement

1. Mesurer la latence de l'appel le plus court et du plus long, et en déduire la taille minimale de tampon.
2. Écrire la politique de repli pour trois cas : latence nominale, latence élevée, indisponibilité du service.
3. Vérifier que la politique de repli ne produit pas de décrochage audible, en mesurant le nombre de décrochages par minute.
4. Proposer un indicateur de surveillance du taux de dépassement de budget, et préciser sa fenêtre de calcul.
5. Écrire en trois lignes ce qui se passe si la latence du service double, et si le repli doit alors changer.

Bareme indicatif

Critere	Points
La taille de tampon est justifiée par une mesure, pas par une convention	4
Les trois cas de repli sont définis et différenciés	3
L'indicateur de dépassement est spécifié	3

A retenir

- Une source synthétique est mobile sans coût, car la position recalcule les trois signaux physique.
- La différence de phase n'est exploitable qu'en dessous d'environ 1 500 hertz.
- Le budget de 40 millisecondes interdit tout appel distant dans le chemin de restitution.
- Un décrochage audible n'est pas un défaut de qualité sonore, mais un défaut de conception du tampon.

Abréviations, notation et ressources de consultation

Annexes

Annexes

Ce cours se termine par deux annexes de référence. La première donne la signification de chaque sigle employé, sous les deux formes — sigle et développé — car la litterature emploie indifféremment l'une ou l'autre. La seconde donne la signification de chaque symbole mathématique : elle permet de relire une démonstration sans revenir au chapitre dont elle est extraite, et de vérifier qu'un même symbole garde le même sens d'un chapitre à l'autre.

Chapitre A.1

Liste des abréviations

Les sigles ci-dessous sont ceux que le cours emploie. Chacun est donné avec sa forme développée et le sens précis qu'il prend ici, qui n'est pas toujours celui qu'on lui donne ailleurs.

Un sigle employé sans être développé oblige le lecteur à le reconnaître au passage, ou à l'abandonner. Le tableau ci-dessous ferme la liste de ceux que le cours emploie : il est exhaustif pour ce document, et non pour la discipline.

Sigle	Forme développée	Sens dans ce cours
ASR	Automatic Speech Recognition	Reconnaissance automatique de la parole, qui transcrit un signal sonore.
GAN	Generative Adversarial Network	Réseau antagoniste génératif, où un générateur affronte un discriminateur.
GRU	Gated Recurrent Unit	Cellule récurrente à portes, plus légère que le LSTM.
Mel	Échelle mel	Échelle de perception auditive, qui espace les fréquences selon le jugement de l'oreille.
MFCC	Mel-Frequency Cepstral Coefficients	Coefficients cepstraux calculés sur une échelle mel.
MMSE	Minimum Mean Square Error	Estimation spectrale de puissance spectrale qui minimise l'erreur moyenne quadratique.
MOS	Mean Opinion Score	Note moyenne d'une écoute subjective, sur une échelle de 1 à 5.
RMSE	Root Mean Square Error	Erreur quadratique moyenne, ramenée à l'échelle des valeurs prédites.
SNR	Signal-to-Noise Ratio	Rapport signal sur bruit, mesuré en décibels.
STFT	Short-Time Fourier Transform	Transformation de Fourier à fenêtre courte, qui donne le spectrogramme.
TTS	Text-to-Speech	Synthèse de la parole à partir du texte.
VITS	Variational Inference with adversarial learning	Synthèse vocale de bout en bout, à inférence variationnelle.
VQ	Vector Quantization	Quantification vectorielle, qui remplace un signal par un indice de code.

Tableau 1 – Abréviations employées dans le cours

Chapitre A.2

Table de notation

Les symboles ci-dessous gardent le même sens d'un chapitre à l'autre. Lorsqu'un chapitre doit réemployer un symbole pour un autre objet, il le redéclare sur la page même.

La notation est celle du cours : vecteurs en gras, matrices en majuscules grasses, scalaires en italique. Les espérances sont notées E, les lois de données D, les espaces de paramètres Θ.

Symbole	Signification
$S(t)$	Signal temporel, fonction du temps t.
f	Fréquence, en hertz.
f_s	Fréquence d'échantillonnage, en hertz.
N	Nombre d'échantillons d'une trame.
L	Longueur de la fenêtre d'analyse, en échantillons.
H	Pas de décalage entre deux trames, en échantillons.
$X[k]$	Coefficient de la transformée de Fourier à court terme à la fréquence k.
$\|X[k]\|$	Module du spectrogramme, qui donne l'énergie.
$S[k]$	Densité de puissance spectrale estimée.
m	Indice de bande mel.
c	Indice de cepstre.
C_j	Coefficient cepstral d'indice j.
$f_0(t)$	Fréquence fondamentale, c'est-à-dire hauteur perçue.
G_{gen}	Générateur, qui produit le signal synthétisé.
G_{disc}	Discriminateur, qui juge le signal reçu.
L_{gan}	Perte antagoniste, minimisée par le générateur et maximisée par le discriminateur.
f_c	Fréquence de la porteuse, en hertz.

Tableau 1 – Symboles mathématiques et leur signification

> **Convention**
> Toute divergence constatée entre cette table et un chapitre signale une erreur de transcription, non une définition nouvelle : la table fait foi.

> **A retenir**
> - Un sigle employé sans être listé ici est un oubli de l'auteur, non une définition nouvelle.
> - Un symbole qui change de sens d'un chapitre à l'autre rend toute démonstration ininterprétable : c'est la principale cause des contresens que nous avons relevés.
> - Ces deux tables sont les seules parties du cours à maintenir à la main : le reste se relit tout seul.

Index des figures et des tableaux

Référence rapide du matériel visuel

Figures

1. De la description textuelle à l'audio : la chaîne de génération
1. Le filigrane sonore : rendre l'origine détectable
1. Audio spatial : la scène écoutée, pas seulement entendue
2. Le temps réel audio : trois budgets qui ne se concertent pas

Tableaux

1. Les cinq étapes et ce qui peut y échouer

1. Les quatre mécanismes qui maintiennent la cohérence
1. Ce que le filigrane garantit et ce qu'il ne garantit pas
1. Codec à formule et codec appris : la comparaison honnête
1. Le partitionnement du budget de 40 millisecondes
1. Abréviations employées dans le cours
1. Symboles mathématiques et leur signification

Fin du document

Intelligence Artificielle Avancée & Federated Learning — Fondations mathématiques de l'apprentissage automatique, algorithmes fédérés, protection de la vie privée, défense contre les attaques, grands modèles de langage fédérés, systèmes embarqués, renforcement appris, applications critiques (santé, V2X), plateforme de référence FedX et feuille de route de recherche.
Ghiloufi Jamel, Architecte Logiciel Principal — Pixel Software Design
Département de Recherche & Développement — Recherche
Pixel Software Design — Édition 2026

© 2026 Pixel Software Design. Tous droits réservés.

Ce document est la propriété exclusive de Pixel Software Design. Toute reproduction, représentation, adaptation ou diffusion, totale ou partielle, par quelque procédé que ce soit et sur quelque support que ce soit, est interdite sans autorisation écrite préalable de l'auteur.

Document généré automatiquement le 29/09/2026 – mise en page Pixel Software Design.