

PIXEL SOFTWARE DESIGN

Département de Recherche & Développement

Intelligence Artificielle Avancée

& Federated Learning

- Fondations de l'intelligence artificielle
- Algorithmes d'apprentissage fédéré
- Confidentialité, attaques et défenses
- Applications et grands modèles fédérés
- Framework FedX de référence
- Nouveaux fronts de recherche
- Travaux pratiques, projets et évaluation

Auteur	**Ghiloufi Jamel**
Fonction	**Architecte Logiciel Principal**
Direction	**Département de Recherche & Développement**
Service	**R&D - Intelligence Artificielle Avancée & Apprentissage Fédéré**
Niveau	**Recherche**
Édition	**Édition 2026 – 1.0**
Copyright	**© Pixel Software Design**

Ce document est la propriété exclusive de Pixel Software Design. Toute reproduction, représentation, adaptation ou diffusion, totale ou partielle, par quelque procédé que ce soit et sur quelque support que ce soit, est interdite sans autorisation écrite préalable de l'auteur.

Copyright et mentions légales

Éditeur	Pixel Software Design
Auteur	Ghiloufi Jamel
Fonction	Architecte Logiciel Principal
Département	Département de Recherche & Développement
Intitulé	Intelligence Artificielle Avancée & Federated Learning
Sous-titre	Fondations mathématiques de l'apprentissage automatique, algorithmes fédérés, protection de la vie privée, défense contre les attaques, grands modèles de langage fédérés, systèmes embarqués, renforcement appris, applications critiques (santé, V2X), plateforme de référence FedX et feuille de route de recherche.
Édition	Édition 2026 (version 1.0)
Langue	Français
Niveau	Recherche
Collection	Supports de formation et de recherche, Pixel Software Design

Droits d'auteur

© 2026 Pixel Software Design. Tous droits réservés.

Ce document est la propriété exclusive de Pixel Software Design. Toute reproduction, représentation, adaptation ou diffusion, totale ou partielle, par quelque procédé que ce soit et sur quelque support que ce soit, est interdite sans autorisation écrite préalable de l'auteur.

Droits de l'auteur. Ghiloufi Jamel est l'auteur unique de l'ensemble du contenu scientifique, pédagogique et technique de cet ouvrage. Toute adaptation, traduction, reproduction ou exploitation, y compris partielle, requiert une autorisation écrite préalable.

Droits des tiers. Les algorithmes, modèles et travaux cités restent la propriété de leurs auteurs respectifs. Les références employées figurent en fin d'ouvrage, ce qui permet de remonter au travail original pour toute affirmation chiffrée.

Marques et licences externes. PyTorch, TensorFlow, Flower, Opacus, MONAI, scikit-learn et PySyft sont des logiciels libres sous licences respectives (BSD, Apache 2.0, MIT). Leur usage dans ce document est purement pédagogique et n'emporte aucune prescription commerciale.

Mentions relatives aux données et aux expérimentations

Document pédagogique à usage de formation interne. Les exemples de code fournis sont livrés à titre pédagogique ; les résultats numériques illustrés sont issus d'expérimentations conduites dans un cadre de recherche et ne constituent pas des performances de production.

Ce support synthétise les travaux de recherche du Département de Recherche & Développement de Pixel Software Design sur l'intelligence artificielle distribuée, l'apprentissage fédéré, la protection de la vie privée et les systèmes embarqués intelligents.

Sommaire

Structure détaillée du cours

Partie 1 — Les quatre axes de l'innovation en IA 8

1.1 De l'IA générative passive à l'IA agentique 9

1.2 La multimodalité native 12

1.3 Efficacité, densité cognitive et Edge AI 14

1.4 IA verticale et systèmes hybrides d'entreprise 16

1.5 Panorama des modèles et influence sur l'économie internationale 18

Annexes 25

A.1 Liste des abréviations 26

A.2 Table de notation 26

Partie	Thème	Contenu	Compétence visée	Durée
Partie 1	Fondations	Statistique, optimisation, courbes d'apprentissage	Comprendre et formaliser	2-3 semaines
Partie 2	Algorithmes FL	FedAvg, convergence, hétérogénéité, système	Implémenter et régler	3-4 semaines
Partie 3	Confidentialité	DP, attaques, défenses, agrégation sécurisée	Auditer et sécuriser	2-3 semaines
Partie 4	Applications	FedLLM, santé, V2X, FedRL, TinyML, graphes	Transposer à un domaine	3-4 semaines
Partie 5	Framework FedX	Architecture, API, benchmarks, exploitation	Industrialiser	2 semaines
Partie 6	Nouveaux fronts	FedCL, FedCI, SNN, FedGL, feuille de route	Ouvrir la recherche	2 semaines
Partie 7	TP et projets	9 labs, 5 projets, corrigés, évaluation	Faire et rendre	4-6 semaines

Préface

Comment utiliser ce cours

Ce support est conçu pour un parcours de formation et de recherche couvrant l'ensemble de la chaîne de valeur de l'intelligence artificielle distribuée : les fondations mathématiques, les algorithmes d'apprentissage fédéré, les menaces et défenses, les applications de pointe, une plateforme de référence opérationnelle, et enfin les nouveaux fronts ouverts par la recherche du Département.

Ce n'est pas un manuel de référence à lire d'un trait : c'est un **manuel opératoire**. Chaque chapitre alterne exposition, formalisation, mise en œuvre numérique et évaluation. Les listings sont complets et exécutables ; les tableaux comparatifs servent de grille de décision ; les schémas d'architecture servent de support de revue de conception.

Public et prérequis

Le contenu s'adresse à des étudiants de master et de doctorat, à des ingénieurs IA et à des praticiens de la recherche appliquée. Les prérequis sont la connaissance de l'apprentissage automatique classique, de l'algorithmique numérique et des bases de probabilités. Les parties 1 à 3 sont auto-suffisantes pour un étudiant qui découvre le domaine ; les parties 4 à 7 supposent la mécanique et les outils présentés dans la partie 2.

Conventions de lecture. Une expression mathématique est encadrée par deux signes dollars ; un identifiant, un fichier ou une commande est écrit en caractères à chasse fixe ; les encadrés *Définition*, *Théorème*, *Méthode* et *Attention* signalent les points à maîtriser et les pièges fréquents. Les renvois de la forme « voir chapitre 3.2 » désignent le second chapitre de la troisième partie.

Progression pédagogique

Agentique, multimodal, efficient, vertical

Partie 1

Les quatre axes de l'innovation en IA

En cinq ans, l'IA est passée d'un objet de laboratoire à une infrastructure. Quatre axes expliquent l'essentiel du mouvement : des systèmes qui agissent au lieu de répondre, des systèmes qui voient et entendent, des systèmes qui tiennent dans un appareil, et des systèmes ancrés dans les données d'une organisation. Ce cours décrit ces axes, puis mesure leur effet sur l'économie internationale.

Objectifs de la partie

- Distinguer un assistant génératif d'un agent, et identifier le niveau d'autonomie réel.
- Expliquer ce qu'exige la multimodalité « native » par rapport à l'assemblage de modules.
- Évaluer le compromis entre taille de modèle, coût d'exploitation et capacité locale.
- Décrire l'architecture d'un système d'entreprisefounded sur la génération augmentée.
- Analyser la concentration de la valeur et la fracture de performance à l'échelle mondiale.

Plan de la partie

1. De l'IA générative passive à l'IA agentique
2. La multimodalité native
3. Efficacité, densité cognitive et Edge AI
4. IA verticale et systèmes hybrides d'entreprise
5. Panorama des modèles et influence sur l'économie internationale

Chapitre 1.1

De l'IA générative passive à l'IA agentique

La rupture n'est pas dans le modèle : elle est dans la boucle qui l'entoure.

Jusqu'à recently, un modèle de langage était un **produit** : on lui soumettait une requête, il renvoyait une réponse. La réponse pouvait être juste, fausse, ou mélange des deux, et l'utilisateur restait le seul juge et le seul executeur. L'IA agentique ne change pas le modèle : elle ajoute une boucle de décision, des outils et une mémoire autour du modèle.

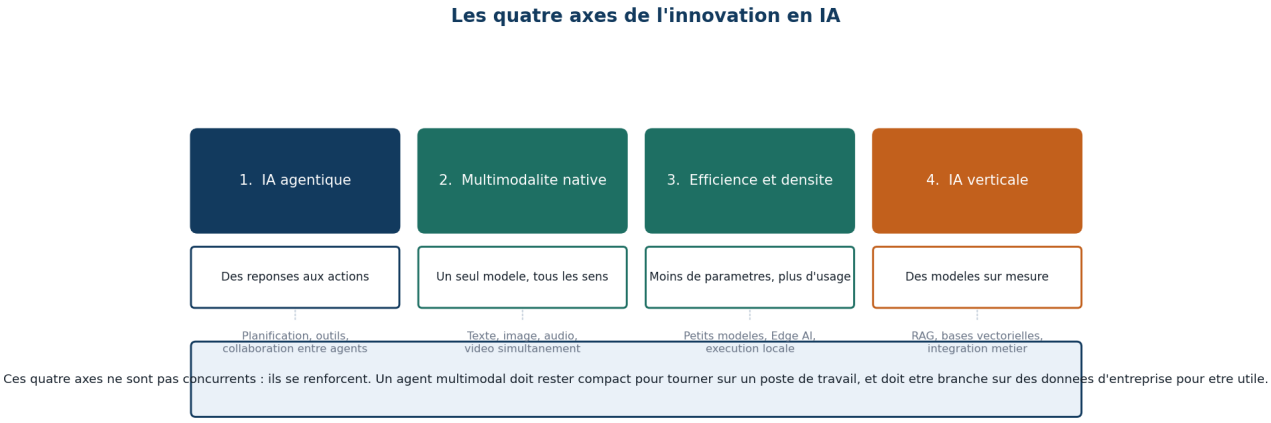


Figure 1 – Les quatre axes de l'innovation et leurs interactions

Ce qu'un agent fait réellement

Un agent est un système qui, reçoit un objectif, décompose cet objectif en étapes, choisit des outils pour exécuter ces étapes, vérifie le résultat obtenu, et répète jusqu'à atteindre l'objectif ou à décider de s'arrêter. Cette définition est volontairement mécanique : elle permet de l'évaluer, et donc de l'auditer.

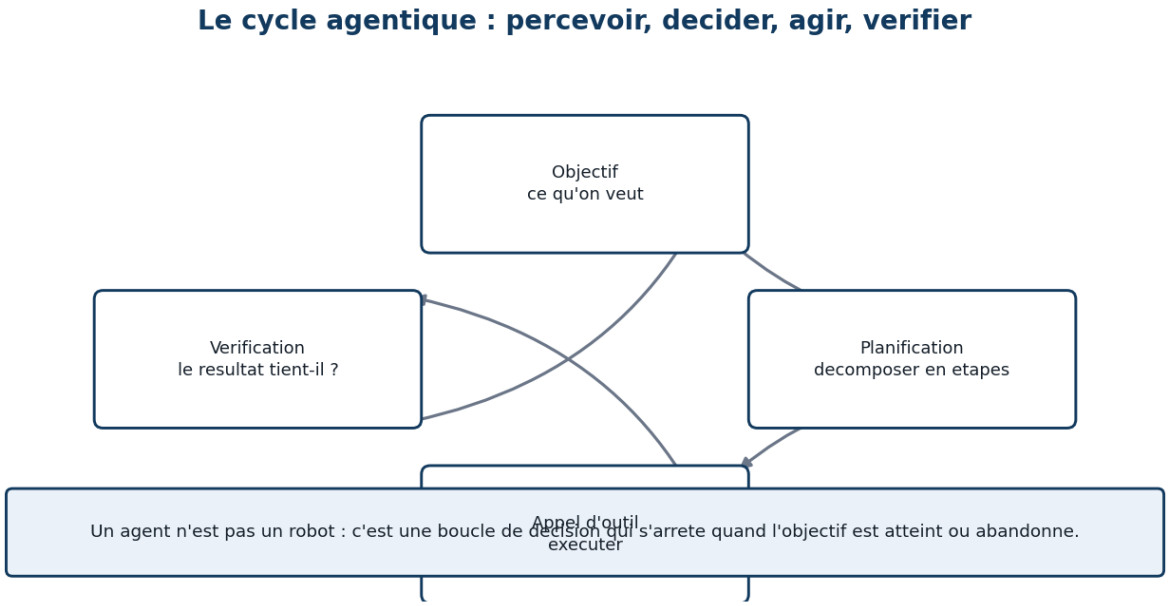


Figure 2 – Le cycle agentique : percevoir, décider, agir, vérifier

Algorithme 1 – Boucle agentique générique

```
01  Recevoir un objectif et un budget (temps, appels, coût)Observer l'état courant : données,
outils disponibles, mémoire
02  Planifier : decomposer l'objectif en étapes vérifiables
03  Agir : appeler un outil (recherche, base, API, execution)
04  Vérifier : l'état obtenu est-il conforme a l'étape prévue ?
05  Si non : corriger le plan et reprendre a l'étape de planification
06  Si oui : passer a l'étape suivante
07  Si toutes les étapes sont validées : produire la réponse finale
08  Dans tous les cas : journaliser actions, coûts et incertitudes
```

Entrées : Objectif, budget, outils, mémoire • **Sorties :** Résultat verifie et trace • **Complexité :** O(k · t) appels, k étapes, t tentatives par étape

La ligne 6 est le cœur du système : sans vérification, un agent n'est qu'un générateur de plans que l'on croît. L'étape 9 est ce qui rend l'agent auditable.

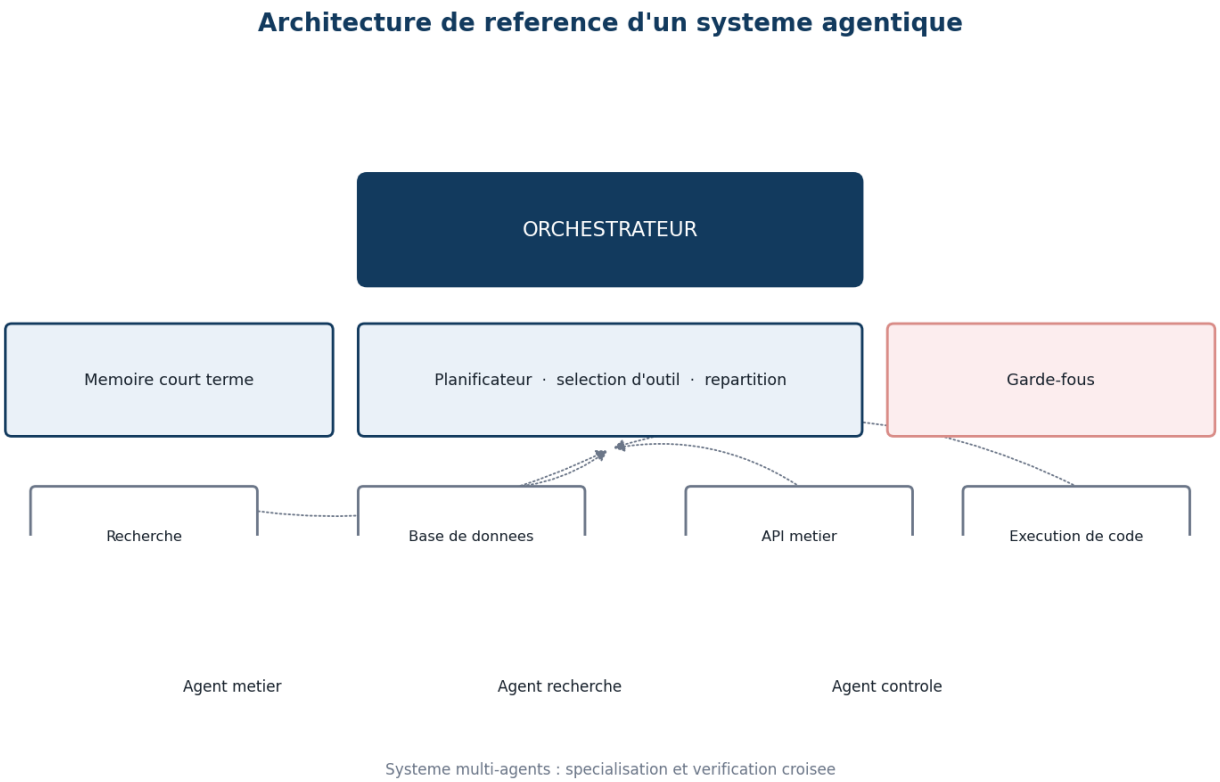


Figure 3 – Architecture de référence d'un système agentique

Les trois niveaux d'autonomie

« Agent » est devenu un mot-valise. Pour raisonner utilement, il faut distinguer trois niveaux, car le risque n'y est pas le même.

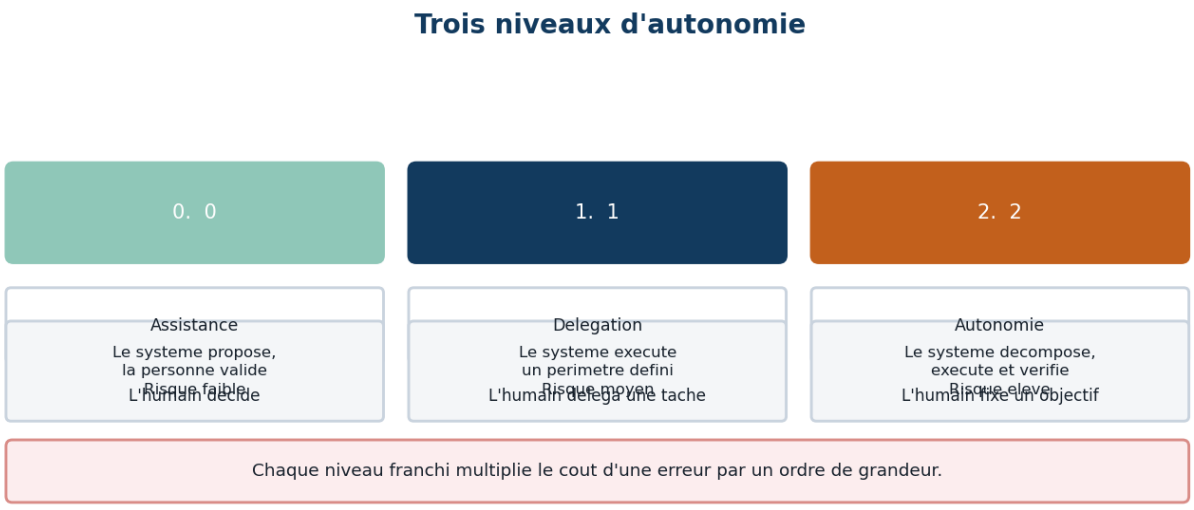


Figure 4 – Trois niveaux d'autonomie et le risque associé

Niveau	L'humain	Ce que fait le système	ExempleContrôle requis	
0 — Assistance	décide et valide chaque actionpropose une réponse ou un plan	assistant de rédaction	relecture humaine systématique	
1 — Délégation	définit une tâche et ses limites	exécute de bout en bout dans un périmètre	remplissage automatique d'un formulaire métier	journalisation et réversibilité
2 — Autonomie	fixe un objectif, supervise a posteriori	planifie, exécute, vérifie, choisit ses outils	réconciliation automatique de deux systèmes de facturation	audit, seuils d'alerte, arrêt d'urgence

Tableau 1 – Comparaison des niveaux d'autonomie d'un système d'IA

Chaque niveau franchi augmente le rayon d'action d'une erreur. Le passage du niveau 0 au niveau 1 est souvent sous-estimé : il déplace la responsabilité vers un dispositif de contrôle.

Les systèmes multi-agents

Un agent unique qui doit tout faire devient fragile : un mauvais outil, une hypothèse fausse, et toute la chaîne s'arrête. L'une des approches dominantes consiste à spécialiser : un agent cherche, un autre vérifie, un troisième décide.

- **Spécialisation :** chaque agent a un rôle et un jeu d'outils restreint, ce qui réduit le risque d'erreur par agent.
- **Vérification croisée :** un agent critique les conclusions d'un autre ; c'est le pendant organisationnel du double contrôle.
- **Dépendance des résultats :** si un agent produit une réponse, l'étape suivante doit pouvoir dire « je n'ai pas su le vérifier ».
- **Coût :** la coordination a un prix en appels et en latence ; un système à six agents n'est pas six fois plus rapide.

L'erreur la plus fréquente en déploiement est de donner à un agent un accès large (messagerie, base, exécution) sans lui donner de moyen de vérifier ce qu'il produit. Il produit alors une suite d'actions plausibles et invérifiables. Le premier livrable d'un projet agentique n'est pas l'agent : c'est l'instrument de vérification.

Un agent sans instrument de mesure est un conjugateur coûteux

Responsabilité

Le cadre européen (AI Act) classe les systèmes selon leur niveau de risque et impose, pour les usages à haut risque, une traçabilité des décisions, une information des personnes concernées et un contrôle humain effectif. Un système agentique n'échappe pas à cette qualification : plus il est autonome, plus la justification de son usage doit être documentée.

A retenir

- L'agent est une boucle de décision autour d'un modèle, pas un modèle nouveau.
- La vérification est ce qui distingue un agent d'un générateur de plans.
- Trois niveaux d'autonomie, trois régimes de risque et de contrôle distincts.
- La multi-agents gagne en robustesse et en spécialisation, pas en vitesse.

Chapitre 1.2

La multimodalité native

Traiter plusieurs médias ne signifie pas les juxtaposer.

Pendant des années, l'architecture courante consistait à faire tourner un modèle par modalité — un module de vision, un module de reconnaissance vocale — puis à transmettre leurs sorties à un modèle de texte. La multimodalité **native** change la donné : un seul modèle reçoit l'image, le son et le texte dans un espace unique, ce qui lui permet de raisonner sur les relations entre eux.

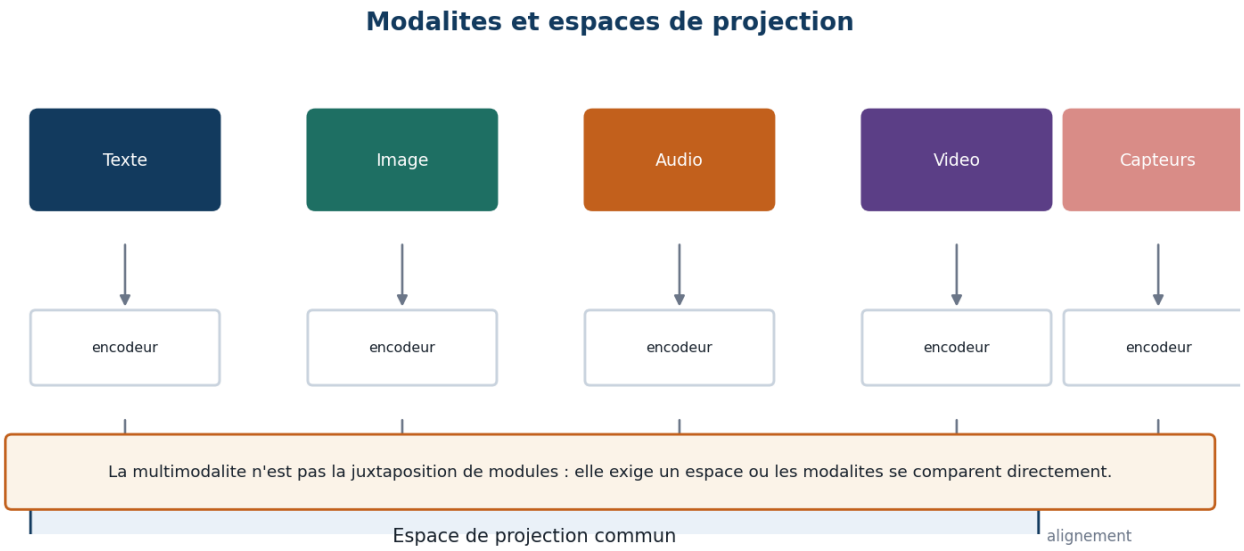


Figure 1 – Modalités, encodeurs et espace de projection commun

Critère	Assemblage de modules	Modalité native
Unité de traitement	un modèle par modalité	un modèle unique
Alignement	appris à la main, souvent fragile	appris pendant l'entraînement
Raisonnement croisé	limité aux interfaces entre modules	direct, sur les données jointes
Latence	somme des latences de chaque module	une seule passe
Coût d'entraînement	plusieurs entraînements distincts	un seul entraînement
Limite	information perdue aux frontières	cohérence globale

Tableau 1 – Assemblage de modules contre modalité native

Le test décisif est simple : poser une question qui exige de croiser deux modalités. « Que se passe-t-il juste après que le client a dit ceci ? » en Combineant l'audio et la vidéo ne fonctionne qu'en natif.

Ce que la multimodalité rend possible

- **Maintenance assistée :** analyser une vidéo de flux et un relevé de température, puis signaler une discordance.
- **Aide à la décision clinique :** croiser un dossier, un compte rendu radiologique et un entretien enregistré.
- **Contrôle d'accès :** comparer une image, une voix et un document d'identité pour authentifier.
- **Robotique :** un agent qui voit, entend et décide de la manipulation à partir de l'environnement réel.

Exemple

Un cas typique de valeur créée par le croisement : un contrôle d'accès. Le visage seul peut être trompé par un masque ; la voix seule peut l'être par un enregistrement. La comparaison des trois signaux dans un même modèle rend la fraude nettement plus coûteuse à mettre en œuvre, sans exiger de règle écrite.

Multimodalité et exécution locale

La multimodalité a longtemps été un obstacle à l'exécution locale : un modèle qui lit, entend et voit occupe fastidement la mémoire. Larchitectures compactes, objet du module suivant, lèvent cette contrainte.

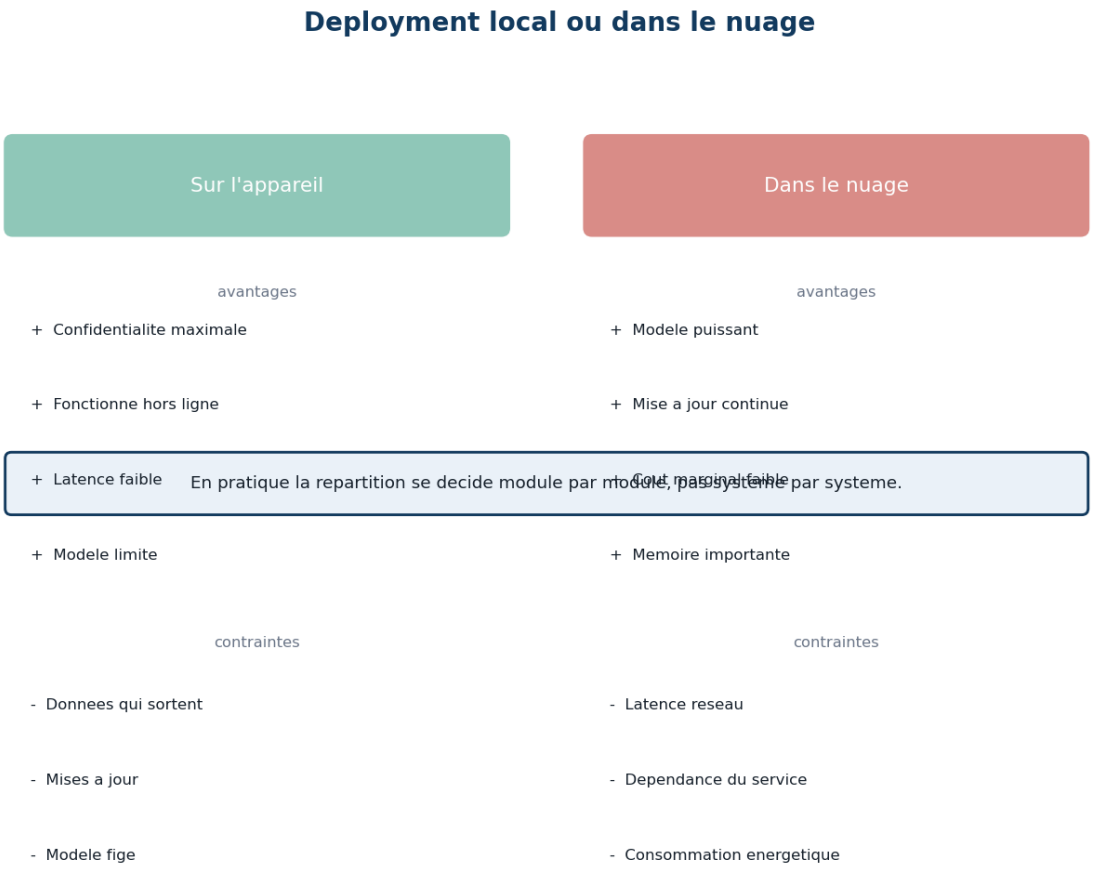


Figure 2 – Déploiement local ou dans le nuage : avantages et contraintes

Latence et gouvernance du temps réel

Un système d'IA qui pilote un équipement ne peut pas tolérer quarante millisecondes d'aller-retour réseau. Le critère de choix du mode de déploiement n'est donc jamais la qualité du modèle, mais le délai maximal toléré par l'usage.

A retenir

- La multimodalité native consiste en un espace de projection commun, pas en un assemblage de modules.
- La valeur apparaît là où une question exige de croiser deux modalités.
- Le mode de déploiement est déterminé par la latence admissible et le régime de confidentialité.

Chapitre 1.3

Efficacité, densité cognitive et Edge AI

La course au nombre de paramètres s'achève : ce qui compte désormais, c'est le raisonnement par unité d'énergie consommée.

La métrique dominante pendant cinq ans a été le nombre de paramètres, parce qu'elle était facile à comparer et à communiquer. Elle est aujourd'hui remplacée par une famille de mesures plus pertinentes : qualité par unité de calcul, par unité de mémoire, et par unité d'énergie.



Figure 1 – Rapprochement de la frontière des gros modèles et des modèles compacts

Ce que recouvre la « densité cognitive »

Definition – Densité cognitive

Rapport entre la qualité d'un modèle et les ressources nécessaires pour l'exécuter. Elle se mesure au minimum sur trois axes : la consommation mémoire à l'inférence, la latence pour une requête, et l'énergie par jeton produit.

Levier	Principe	Gain typique	Coût ou limite
Quantification	réduire la précision des poids2 à 4 fois moins de mémoire	perte de précision à surveiller	
Distillation	transférer le savoir d'un grand modèle	modèle nettement plus petit	nécessite l'accès au grand modèle
Quantification + ajustement	recalibrer après réduction	récupère l'essentiel de la perte	coût d'entraînement ajouté
Adaptation de faible rang	ne entraîner qu'un adaptateur	quelques pour cent des paramètres	incompatible avec l'exécution sans adaptateur
Réseau neuroshape	contrôler la fréquence et l'énergie	très faible consommation	modèles plus specializeds

Tableau 1 – Comment un modèle compact devient compact

La quantification est le levier le plus rentable et le plus sous-estimé : pour un besoin de raisonnement courant, réduire la précision des poids change rarement le comportement observable.

Pourquoi l'exécution locale redevient rentable

- **Confidentialité :** la donnée ne quitte pas le poste ni l'entreprise, ce qui lève une contrainte juridique sans compromettre sur le modèle.
- **Fonctionnement hors ligne :** l' Terminal reste utile sans réseau, ce qui compte en mobilité, en industrie et en santé.
- **Coût marginal :** l'inférence locale ne coûte rien par requête une fois l'appareil amorti.
- **Latence :** absence d'aller-retour réseau, donc un comportement prévisible et boré.

« Hors ligne » a un prix caché

Un modèle exécuté localement n'est plus mis à jour. La maintenance d'une flotte d'appareils gravité est un travail d'exploitation à part entière : distribution des versions, vérification de l'intégrité, retour arrière en cas de régression. Ce coût est rarement chiffré au moment du choix, et il est le premier motif d'abandon de l'Edge AI en production.

Où reste-t-il pertinent d'utiliser un gros modèle ?

La compactisation ne supprime pas les modèles de grande taille ; elle en restreint l'usage aux tâches qui le justifient. Un système hybride est la configuration la plus courante : un modèle local pour le traitement courant, un modèle distant pour la génération complexe, et un aiguillage explicite entre les deux.

Astuce

Le bon indicateur de choix n'est pas la taille du modèle mais le taux d'échappement : la proportion de requêtes que le système local ne sait pas traiter et qu'il faut transmettre. En dessous de dix pour cent, l'hybride est presque toujours le bon choix.

A retenir

- La taille du modèle a cessé d'être le bon indicateur ; la densité cognitive l'a remplacée.
- La quantification est le levier le plus rentable et le plus immédiat.
- L'exécution locale résout la confidentialité et la latence, mais déplace le coût vers la maintenance du parc.
- La configuration industrielle courante est hybride, avec aiguillage explicite entre modèle local et modèle distant.

Chapitre 1.4

IA verticale et systèmes hybrides d'entreprise

Un modèle généraliste ne connaît rien de votre métier. Toute la valeur se construit dans la couche d'accès à vos données.

Les entreprises délaissent progressivement les outils généralistes au profit d'architectures ancrées dans leurs propres données et dans leurs propres processus. Ce mouvement porte un nom : l'IA verticale.

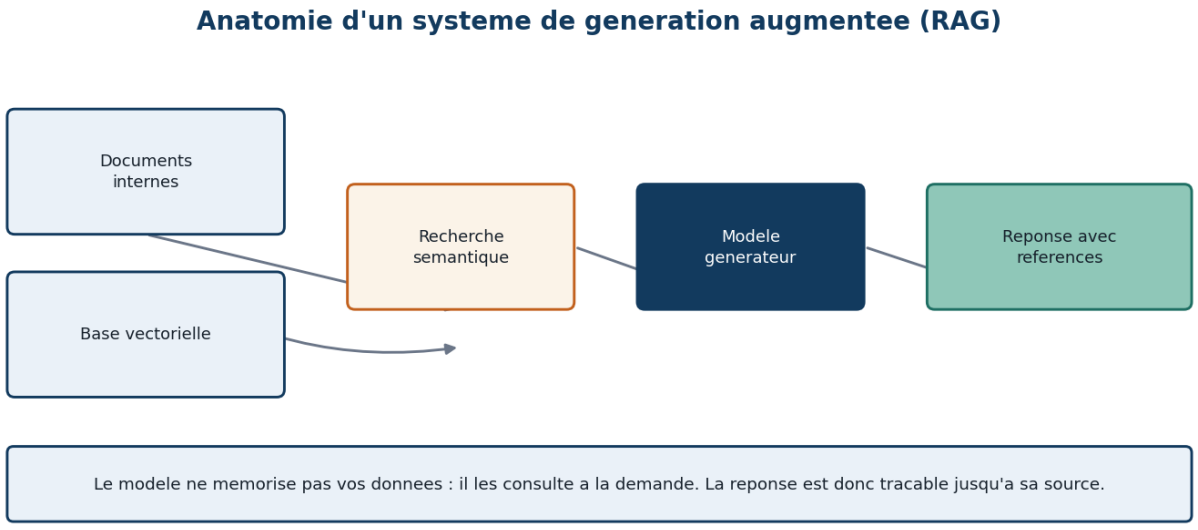


Figure 1 — Anatomie d'un système de génération augmentée

La génération augmentée par récupération

Le mécanisme central est le **RAG** (retrieval-augmented génération). Au lieu de demander au modèle de connaître une information, on lui fournit les passages pertinents au moment de la question, puis on lui demande de rédiger une réponse fondée dessus.

Algorithme 2 – Cycle d'une interrogation en génération augmentée

```
01  Reformuler la question de l'utilisateur en requête de rechercheRechercher les passages
proches dans la base vectorielle
02  Filtrer par permissions, date et source autorisée
03  Assembler les passages retenus avec la question
04  Demander au modèle de répondre en citant les passages
05  Vérifier que chaque affirmation est attribuable a un passage
06  Renvoyer la réponse et les références, ou une absence de réponse
```

Entrées : Question, droits d'accès de l'utilisateur • **Sorties :** Réponse sourcée, ou refus explicite • **Complexité :** O(N log d) pour la recherche, un appel modèle par question

La dernière ligne est la plus importante : un système qui répond à tout, même quand la base ne contient pas la réponse, est pire qu'un système qui ne répond pas. Le refus est un comportement à concevoir.

La base vectorielle n'est pas une base de connaissances

La recherche par similarité s'appuie sur la proximité vectorielle entre la question et les passages. Cette proximité mesure une ressemblance de formulation, pas une pertinence factuelle. Un passage sur les « taux d'intérêt » peut être sélectionné pour une question sur le « taux d'usure ». L'indexation, le découpage des documents et le filtrage méthodologique pèsent autant que le modèle lui-même.

L'intégration dans les logiciels métier

Au-delà de la simple interrogation, l'IA s'insère dans la chaîne de valeur : elle prépare la facture, rapproche le bon de commande, rédige la réponse de support, anticipe la panne. Cette intégration se fait par couche, du plus stable au plus volatil.



Figure 2 – Insertion de l'IA dans la chaîne de valeur de l'entreprise

Couche	Rôle	Propriétaire	Risque dominant
Données	sources, qualité, traçabilité	direction des donnéesdonnée obsolète ou non conforme	
Services	recherche, index, journal d'audit	équipe plateforme	permissions mal appliquées
Modèles	modèle généraliste, ajusté, règles métier	équipe modèle	dérive de performance
Agents	routage, rédaction, contrôle, escalade	équipe produit	action non réversible
Usages	support, facturation, prévision	métier	confiance excessive

Tableau 1 – Les couches d'un système d'IA d'entreprise

L'erreur la plus coûteuse consiste à commencer par la couche agents : sans couche de données fiable et journalisée, l'automatisation ne fait qu'exécuter plus vite des erreurs.

Ce qui distingue un déploiement réussi d'un gadget

- Il porte sur **un processus** mesurable, pas sur une fonction marketing.
- Il dispose d'un **critère d'abandon** écrit dès le départ.
- Il journalise **chaque décision** de façon à pouvoir être rejouée.
- Il prévoit un **retour arrière** : le système sait défaire ce qu'il a fait.
- Il est évalué sur le temps gagné **net** de la supervision ajoutée.

A retenir

- Toute la valeur de l'IA verticale se construit dans la couche d'accès aux données propres.
- La génération augmentée impose de concevoir le refus comme un comportement normal.
- L'intégration doit suivre les couches, des données vers les usages, jamais l'inverse.
- Un projet sans critère d'abandon écrit ni retour arrière est un gadget à date d'expiration.

Chapitre 1.5

Panorama des modèles et influence sur l'économie internationale

Où en est la technologie, et — surtout — qui en tire la valeur.

Ce dernier module n'est pas un catalogue de produits : c'est une lecture économique. La question utile n'est pas « quel modèle est le meilleur ? » mais « qui capte la valeur créée, et à quelles conditions ».

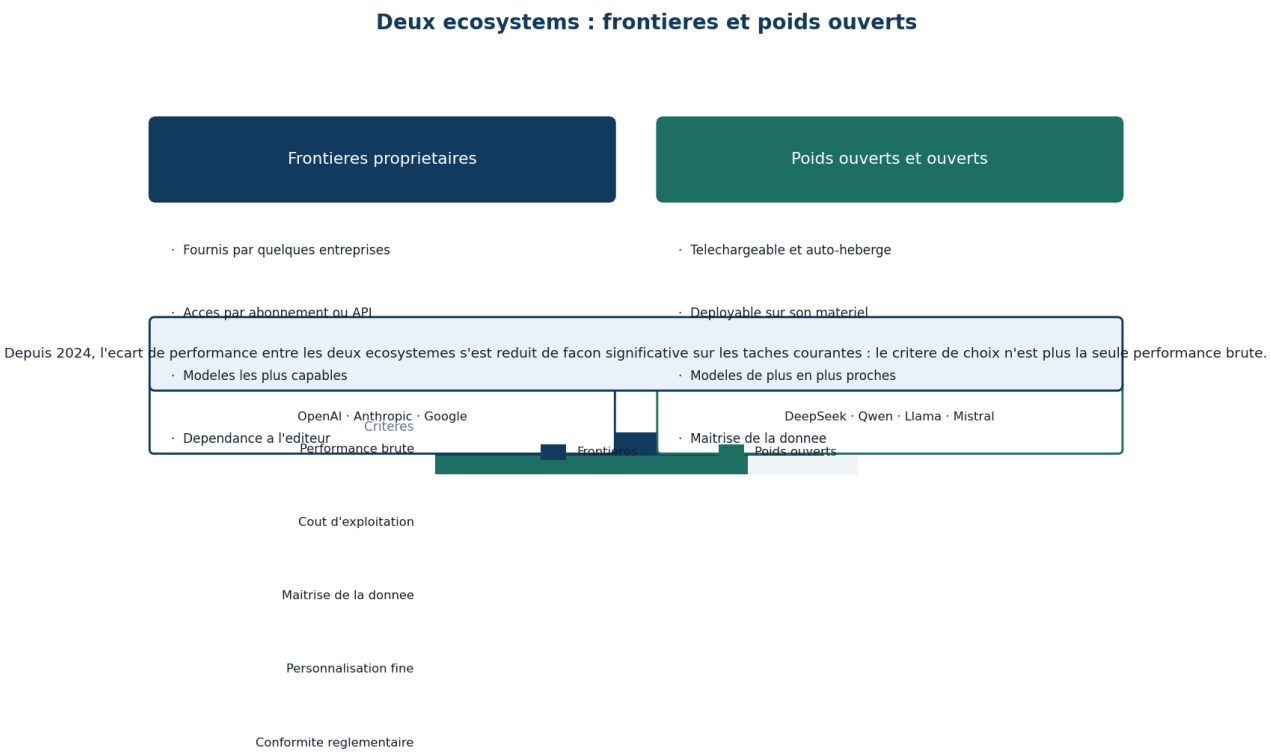


Figure 1 — Frontières propriétaires et poids ouverts : deux logiques de déploiement

L'état d'avancement des modèles de pointe

- **Raisonnement adaptatif :** les modèles de pointe allouent dynamiquement un effort de calcul à la question, ce qui allonge le délai de réponse mais améliore la justesse sur les problèmes difficiles.
- **Correction de leurs propres erreurs :** la Capacity à vérifier et reprendre un raisonnement remplace en partie la boucle externe, ce qui est la condition de l'autonomie.
- **Multimodalité native :** texte, vision et audio traités dans un même modèle, avec alignement appris pendant l'entraînement.
- **Usage d'outils :** appel de fonctions, consultation de bases et exécution de code deviennent des capacités natives du modèle.
- **Compétences verticales :** les fournisseurs exposent des interfaces dédiées au code, au droit, à la recherche biomédicale et à l'automatisation des systèmes de gestion.

L'investissement et les infrastructures



Figure 2 – Investissements et dépenses d'infrastructure : ordres de grandeur mondiaux

Le fait marquant de la période n'est pas le volume investi mais sa **nature**. La dépense d'infrastructure — centres de données, puces d'accélération, énergie — a dépassé l'investissement en recherche. L'IA est devenue un bien de capital à part entière, ce qui a des conséquences sur la structure du marché : très peu d'acteurs peuventlux financer ce niveau d'engagement.

Position	Ce qui la caractérise	Exemple d'avantageFacteur de vulnérabilité	
Pionniers	redéfinissent un processus entiercoût unitaire en baisse, délai de cycle réduit	dépendance à l'éditeur de modèle	
Suivants	intègrent l'IA à un processus existant	gain de productivité ciblé sur une étape	données moins spécifiques
Grand public	utilisent des outils génériques	accès à la capacité sans investissement	aucun avantage défendable à long terme

Tableau 1 – Où se concentre la valeur créée

Le gain se mesure en restructuration de processus, pas en ajout d'outils. C'est la distinction centrale de toutes les études d'impact.

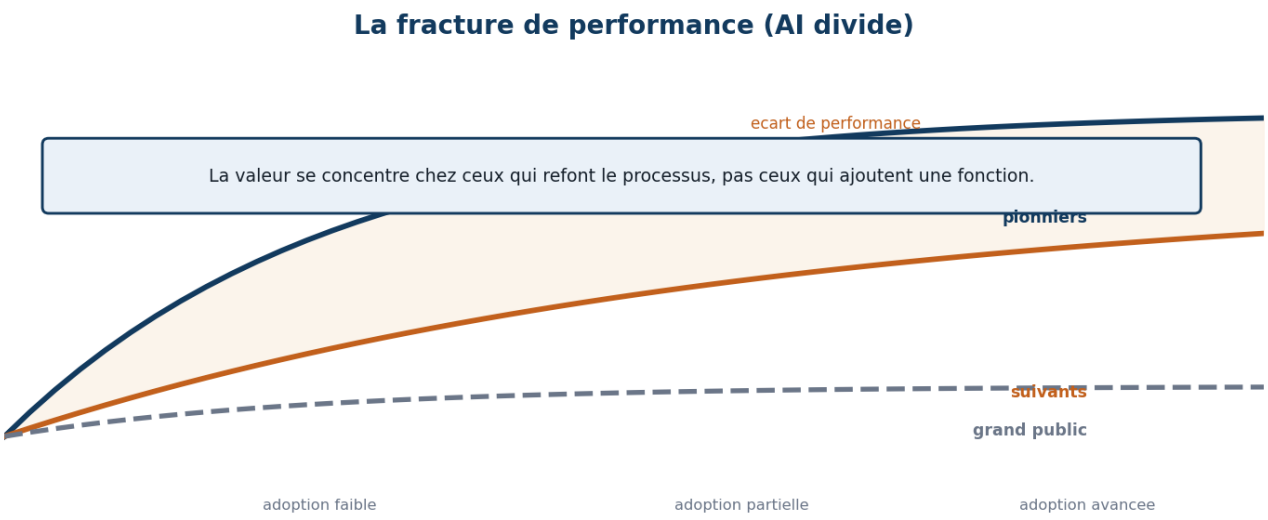


Figure 3 – Fracture de performance : l'écart se creuse avec l'adoption

La transformation du marché du travail

L'effet le mieux documenté n'est pas une disparition d'emplois, mais un déplacement de la valeur à l'intérieur du poste. Ce qui coûte cher — exécuter, saisir, trier, rédiger un premier jet — baisse. Ce qui augmente — vérifier, arbitrer, décider — augmente.



Figure 4 – Les trois déplacements de valeur dans le travail

- **Automatisation des tâches répétitives :** développement logiciel, support de premier niveau, traitement documentaire.

- **Transition vers la supervision :** le travail devient vérifier et corriger plutôt que produire.
- **Dérive des compétences :** la vitesse d'adaptation devient plus déterminante que le stock de connaissances initiales.
- **Concentration :** la valeur se déplace vers les postes qui définissent le problème et arbitrent des cas ambigus.

> **Cadre juridique et ethique**
> Cadre de gouvernance. Le règlement européen sur l'intelligence artificielle (2024/1689) classe les systèmes par niveau de risque, impose la transparence pour les applications interagissant avec les personnes, et prévoit des obligations renforcées pour les usages sensibles — santé, emploi, crédit, sécurité. Cette classification constitue aujourd'hui une contrainte de conception, au même titre qu'une exigence juridique.

La souveraineté technologique

Les États ont compris que la maîtrise des ressources de l'IA conditionné leur capacité de négociation. La question n'est plus « quel modèle est le meilleur » mais « quel maillon peut-on contrôler ».

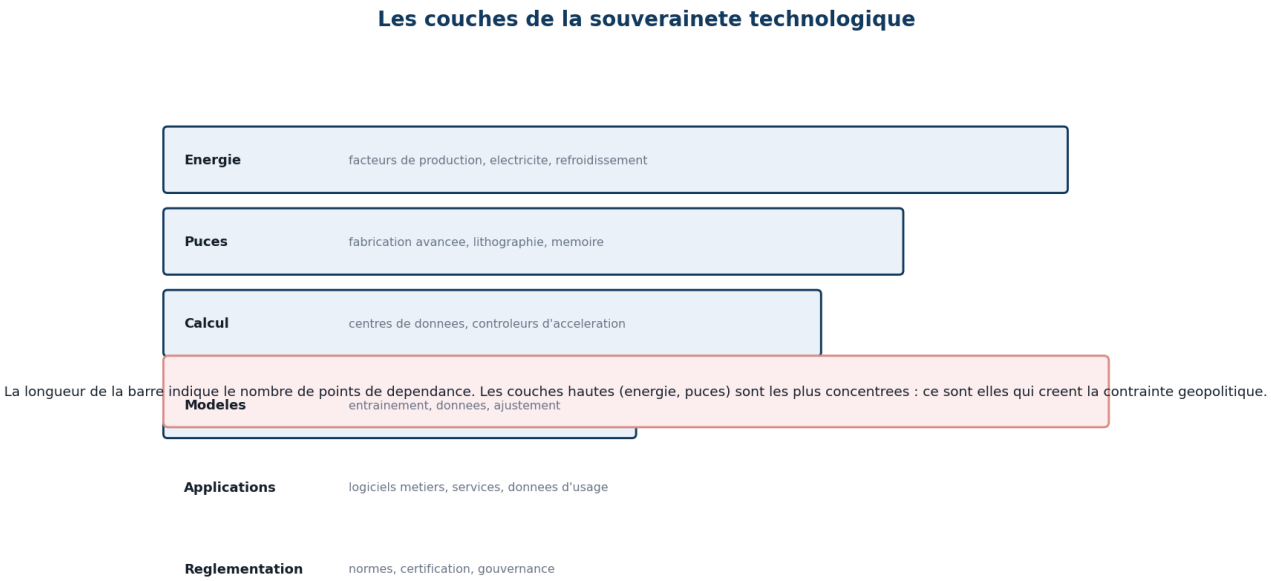


Figure 5 – Les couches de la souveraineté technologique et leurs dépendances

Couche	Concentration	Point de bascule	Levier d'un État
Énergie	élevée	accès à l'électricité et au refroidissementcontrats de long terme, énergie nucléaire	
Puces	très élevée	fabrication avancée et mémoire	subventions à la conception, capacités de packaging
Calcul	élevée	centres de données et accélérateurs	souveraineté des données, implantation régionale
Modèles	moyenne	accès aux poids et aux talents	écosystèmes ouverts, financement de la recherche
Applications	faible	données d'usage et processus métier	normalisation sectorielle, interopérabilité
Réglementation	moyenne	normes et reconnaissance mutuelle	participation active aux travaux de normalisation

Tableau 2 – Les couches de dépendance et leurs points de bascule

Un État peut agir sur les couches basses (énergie, puces) ou hautes (modèles, applications) ; l'autonomie complète sur toutes les couches n'est la position d'aucun acteur aujourd'hui.

Astuce

La question opérationnelle la plus utile pour une direction générale est de situer ses dépendances : pour chacune de ses fonctions critiques, quelles couches de ce tableau sont déléguées à des tiers, et avec quelle alternative ?

A retenir

- L'état des modèles est characterised par le raisonnement adaptatif, la multimodalité native et l'usage d'outils.
- La valeur se concentre chez qui refont un processus, pas chez qui ajoutent un outil.
- Le marché du travail se déplace de l'exécution vers le contrôle et l'arbitrage.
- La souveraineté se joue couche par couche ; l'autonomie complète reste hors de portée de tout acteur.

Sources et références de ce module

Les chiffres cités dans ce module sont des ordres de grandeur issus de publications publiques. Ils sont donnés comme ordres de grandeur et non comme valeurs exactes, parce que les périmètres de mesure diffèrent d'une étude à l'autre.

- **axis** — FPT Software — State of AI 2025, axe « agents IA ».; Innowise — veille technologique, axe multimodalité.; Switas Consultancy — veille « IA de pointe », axes multimodalité et efficience.; MaCertif — dossier Edge AI et modèles compacts.; LLMBase — panorama des familles de modèles de pointe.; McKinsey Global Survey on AI — usages et gains de productivité.; PwC — Global AI Study, mesure de la concentration de la valeur.; Stanford HAI — AI Index Report, effets sur l'emploi et l'investissement.; Règlement (UE) 2024/1689 (AI Act) — Journal officiel de l'Union européenne.

Les quatre axes décrits dans ce cours suivent les veilles sectorielles de FPT Software, Innowise, Switas Consultancy, MaCertif et LLMBase ; l'analyse économique s'appuie sur les travaux de McKinsey, PwC et Stanford HAI, complétés par le cadre réglementaire européen.

Abréviations, notation et ressources de consultation

Annexes

Annexes

Ce cours se termine par deux annexes de référence. La première donne la signification de chaque sigle employé, sous les deux formes — sigle et développé — car la litterature emploie indifféremment l'une ou l'autre. La seconde donne la signification de chaque symbole mathématique : elle permet de relire une démonstration sans revenir au chapitre dont elle est extraite, et de vérifier qu'un même symbole garde le même sens d'un chapitre à l'autre.

Chapitre A.1

Liste des abréviations

Les sigles ci-dessous sont ceux que le cours emploie. Chacun est donné avec sa forme développée et le sens précis qu'il prend ici, qui n'est pas toujours celui qu'on lui donne ailleurs.

Un sigle employé sans être développé oblige le lecteur à le reconnaître au passage, ou à l'abandonner. Le tableau ci-dessous ferme la liste de ceux que le cours emploie : il est exhaustif pour ce document, et non pour la discipline.

Sigle	Forme développée	Sens dans ce cours
AGI	Artificial General Intelligence	Intelligence artificielle générale, horizon de long terme.
API	Application Programming Interface	Interface d'échange entre deux logiciels.
CAPEX	Capital Expenditure	Dépense d'investissement, amortie sur plusieurs exercices.
FPT	Formation professionnelle technologie	Parcours de formation addressing l'adaptation des métiers.
HAI	Human-AI	Collaboration entre une personne et un système automatique.
IA	Intelligence artificielle	Ensemble des techniques qui produisent des comportements intelligents.
LLM	Large Language Model	Grand modèle de langage.
MVP	Minimum Viable Product	Version minimale d'un produit, livrée pour tester une hypothèse.
ONG	Organisation non gouvernementale	Acteur extérieur à l'entreprise.
OPEX	Operating Expenditure	Charge d'exploitation, qui se répète d'un exercice à l'autre.
UE	Union européenne	Dont le règlement sur l'intelligence artificielle structure le marché européen.
VAE	Variational Auto-Encoder	Auto-encodeur variationnel, qui sert de modèle génératif.

Tableau 1 – Abréviations employées dans le cours

Chapitre A.2

Table de notation

Les symboles ci-dessous gardent le même sens d'un chapitre à l'autre. Lorsqu'un chapitre doit réemployer un symbole pour un autre objet, il le redéclare sur la page même.

La notation est celle du cours : vecteurs en gras, matrices en majuscules grasses, scalaires en italique. Les espérances sont notées E, les lois de données D, les espaces de paramètres Θ.

Symbole	Signification
R_t	Recette de la période t.
C_t	Charge totale de la période t.
B_t	Solde de trésorerie en fin de période t.
V_k	Valeur d'une option d'investissement k.
r	Taux d'actualisation.
$NPV = \sum_{t=0}^{T} (R_t - C_t)/((1+r)^t)$	Valeur actuelle nette d'un projet.
T	Horizon de la projection financière, en périodes.
ROAI	Retour sur investissement, exprimé en pourcentage.
I_k	Indice d'attractivité du projet k.
λ_k	Pondération du critère k dans l'indice d'attractivité.
$T_{adoption}$	Délai d'adoption par le marché visé.

Tableau 1 – Symboles mathématiques et leur signification

Convention

Toute divergence constatée entre cette table et un chapitre signale une erreur de transcription, non une définition nouvelle : la table fait foi.

A retenir

- Un sigle employé sans être listé ici est un oubli de l'auteur, non une définition nouvelle.
- Un symbole qui change de sens d'un chapitre à l'autre rend toute démonstration ininterprétable : c'est la principale cause des contresens que nous avons relevés.
- Ces deux tables sont les seules parties du cours à maintenir à la main : le reste se relit tout seul.

Index des figures et des tableaux

Référence rapide du matériel visuel

Figures

1. Les quatre axes de l'innovation et leurs interactions
2. Le cycle agentique : percevoir, décider, agir, vérifier
3. Architecture de référence d'un système agentique
4. Trois niveaux d'autonomie et le risque associé
1. Modalités, encodeurs et espace de projection commun
2. Déploiement local ou dans le nuage : avantages et contraintes
1. Rapprochement de la frontière des gros modèles et des modèles compacts
1. Anatomie d'un système de génération augmentée
2. Insertion de l'IA dans la chaîne de valeur de l'entreprise
1. Frontières propriétaires et poids ouverts : deux logiques de déploiement
2. Investissements et dépenses d'infrastructure : ordres de grandeur mondiaux
3. Fracture de performance : l'écart se creuse avec l'adoption
4. Les trois déplacements de valeur dans le travail
5. Les couches de la souveraineté technologique et leurs dépendances

Tableaux

1. Comparaison des niveaux d'autonomie d'un système d'IA
1. Assemblage de modules contre modalité native
1. Comment un modèle compact devient compact
1. Les couches d'un système d'IA d'entreprise
1. Où se concentre la valeur créée
2. Les couches de dépendance et leurs points de bascule
1. Abréviations employées dans le cours
1. Symboles mathématiques et leur signification

Fin du document

Intelligence Artificielle Avancée & Federated Learning — Fondations mathématiques de l'apprentissage automatique, algorithmes fédérés, protection de la vie privée, défense contre les attaques, grands modèles de langage fédérés, systèmes embarqués, renforcement appris, applications critiques (santé, V2X), plateforme de référence FedX et feuille de route de recherche.
Ghiloufi Jamel, Architecte Logiciel Principal — Pixel Software Design
Département de Recherche & Développement — Recherche
Pixel Software Design — Édition 2026

© 2026 Pixel Software Design. Tous droits réservés.

Ce document est la propriété exclusive de Pixel Software Design. Toute reproduction, représentation, adaptation ou diffusion, totale ou partielle, par quelque procédé que ce soit et sur quelque support que ce soit, est interdite sans autorisation écrite préalable de l'auteur.

Document généré automatiquement le 29/09/2026 – mise en page Pixel Software Design.